ANALYSE NON SUPERVISÉE — PROJET 2 — 2025–2026

Qualité de l'air

Séparation de sources de pollution & détection d'anomalies

Anas Mohamed Draoui

Projet individuel — contrainte de temps documentée

Dataset	UCI Air Quality — 9 357 mesures horaires
Période	Mars 2004 – Février 2005, carrefour urbain (Italie)
Difficulté	★★★○○ (Projet 2/3)
GitHub	`github.com/Monarch7-NS/Project-machine-learning--Qualite-de-l-air-urbain.git`

"Imaginez entrer dans une salle où trois conversations se déroulent en même temps. Votre cerveau isole chaque voix naturellement. Ce projet, c'est exactement ça — mais appliqué aux polluants atmosphériques."

Résumé

Pipeline complet d'analyse non supervisée : nettoyage, ACP (PC1 = 74.2%), ICA (3 sources), K-Means (silhouette = 0.36, ARI = 0.16) et DBSCAN (442 anomalies, 4.7%). Rapport rédigé en LaTeX.

Contexte, données et nettoyage

Contrainte de temps : Un empêchement personnel m'a contraint à travailler avec **une semaine de moins** que prévu. J'ai choisi de privilégier un pipeline solide et justifiable à l'oral plutôt que de multiplier les algorithmes sans les comprendre. Chaque décision technique ci-dessous est délibérée.

▶ Pourquoi ce sujet

J'ai choisi le Projet 2 parce que le problème posé me semblait le plus ancré dans la réalité physique. "Démêler les sources de pollution" c'est exactement le *cocktail party problem* : plusieurs sources mélangées dans un seul capteur, et l'objectif est de les séparer. Le lien avec l'ICA m'a semblé immédiat et bien motivé.

▶ Structure du dataset

Le dataset UCI Air Quality contient 9 357 mesures horaires sur un an : concentrations de référence (CO, C_6H_6, NOx, NO_2, O_3), signaux capteurs chimiques (`PT08.Sx`), et variables météo (T, RH, AH).

▶ Nettoyage : le piège des -200

La première surprise : les NaN ne sont pas des `NaN` standard mais **encodés -200**. Ce détail non documenté aurait totalement biaisé la variance et toute l'ACP. NMHC(GT) étant vide à 90.2%, je l'ai supprimée. Pour les autres colonnes, j'ai utilisé `interpolate(method="time")` plutôt qu'une moyenne : avec des séries horaires, le contexte local (7h → NaN → 9h) est bien plus informatif que la moyenne annuelle.

Colonne	% NaN
`NMHC(GT)`	**90.2%**
`CO(GT)`	18.0%
`NOx(GT)`	17.5%
`NO2(GT)`	17.5%
`PT08.Sx`	3.9%
Restants	**0**

```python
df = df.replace(-200, float("nan"))          # demasquer les NaN codes -200
df_poll = df_poll.interpolate(method="time").fillna(method="bfill")
# --> 0 NaN restants sur 9357 x 9 variables
```

▶ Exploration : ce que les données racontent avant tout algorithme

Avant de lancer quoi que ce soit, j'ai vérifié la cohérence physique. Le CO a une moyenne de 2.1 mg/m^3 mais un max à 11.9 — distribution fortement asymétrique, signe d'épisodes rares mais intenses. Le benzène ($r \approx 0.85$ avec CO) et le CO covarient : tous deux issus de la combustion moteur. L'ozone est négativement corrélé aux NOx — exactement la réaction photochimique attendue. Tout ça *avant* d'ouvrir scikit-learn.

Le profil horaire du CO montre deux pics à 8h–9h et 18h–20h (heures de pointe), et les concentrations augmentent en hiver (inversions thermiques, chauffage). La physique valide les données.

Réduction de dimension : ACP et ICA

▶ ACP : structure globale

Après standardisation (indispensable : CO en mg/m^3 vs capteurs à ∼1000), l'ACP révèle une structure très concentrée :

Axe	Var.	Cum.
PC1	**74.2%**	**74.2%**
PC2	12.8%	87.0%
PC3	4.5%	**91.5%**
PC4	2.6%	94.0%
Seuil 90%		**3 axes**

PC1 à 74.2% c'est impressionnant : tous les polluants y chargent positivement. C'est un axe "niveau général de pollution" — quand le trafic est dense ou la dispersion bloquée, tout monte ensemble. PC2 (12.8%) oppose l'ozone aux autres polluants, reflétant la compétition chimique ozone/NOx.

Limite clé de l'ACP : PC1 et PC2 sont décorrélées, pas *indépendantes*. L'ACP est aveugle à l'indépendance statistique — elle ne peut pas séparer "trafic" de "chauffage" si les deux montent parfois en même temps. C'est précisément pour ça que j'ai ensuite appliqué l'ICA.

▶ ICA : séparation des sources

L'ICA (FastICA) suppose un mélange linéaire de sources statistiquement indépendantes. L'hypothèse physique tient : trafic, chauffage et photochimie n'ont aucune raison d'être statistiquement liés. FastICA maximise la non-gaussianité — par le TCL, défaire un mélange revient à maximiser ce critère.

Vérification préalable : le kurtosis.

Variable	Kurt.	
NOx(GT)	3.53	✓ non gaussien
CO(GT)	2.39	lég. leptokurtique
C_6H_6(GT)	2.32	lég. leptokurtique
NO_2(GT)	0.70	≈ gaussien
PT08.S5(O3)	-0.05	gaussien
IC1	2.44	—
IC2	**3.27**	meilleure sép.
IC3	1.17	source diffuse

Soyons honnêtes : les kurtosis sont modérés. NOx est le seul clairement non gaussien (3.53). Les capteurs `PT08`, lissés par la calibration électronique, tendent vers la gaussienne. L'ICA s'applique, mais son efficacité de séparation est réduite sur ces variables. IC2 charge sur NOx/NO_2 (source diesel), ce qui reste physiquement interprétable, mais IC3 est plus diffus.

ACP	ICA
Maximise la **variance**	Maximise l'**indépendance statistique**
Composantes décorrélées	Composantes statistiquement indépendantes
PC1 = "tout monte ensemble"	IC2 = signal NOx/NO_2 distinct
Ordonnées par variance	Sans ordre naturel

Clustering : K-Means et détection d'anomalies DBSCAN

▶ Étape 1 : pseudo-labels et évaluation supervisée

Pour évaluer le clustering sans tricher, j'ai construit un indice de pollution (moyenne normalisée de CO, NOx, NO_2, C_6H_6) discrétisé en trois catégories par terciles. Ces labels ne sont *jamais* passés au modèle — ils servent uniquement à calculer l'ARI a posteriori.

> La distribution révèle un fort déséquilibre : **85.0%** Bon (7 953), **14.0%** Moyen (1 308), **1.0%** Mauvais (96). Ce déséquilibre conditionne directement les scores obtenus : K-Means n'aura presque pas de signal sur la catégorie "Mauvais".

▶ Étape 2 : K-Means sans labels

Après méthode du coude et silhouette, j'ai retenu $k = 3$:

Métrique	Valeur
Silhouette ($k = 3$)	0.360
ARI vs pseudo-labels	0.162
Inertie ($k = 2$)	42 180
Inertie ($k = 3$)	29 450
Inertie ($k = 4$)	24 100

L'ARI de 0.162 peut paraître faible. Il se justifie par le déséquilibre des labels (85% "Bon") et par la nature physique du problème : la qualité de l'air est un **continuum**, pas trois boîtes discrètes. Forcer des données fluides dans $k = 3$ clusters produira toujours des chevauchements aux frontières. C'est un échec du paradigme de clustering à frontières nettes, pas nécessairement de l'algorithme.

Ce qu'on perd sans labels : toute référence externe pour calibrer le sens physique des clusters. On sait qu'il y a 3 groupes, mais pas lesquels correspondent à "bon", "moyen" ou "mauvais".

▶ Détection d'anomalies : DBSCAN

DBSCAN ne suppose aucune forme de cluster et marque comme "bruit" les points isolés dans des régions peu denses — exactement l'outil pour des épisodes de pollution exceptionnels. Pour choisir ε, j'ai utilisé la courbe de distance au 5ème plus proche voisin et retenu le 97ème centile ($\varepsilon = 0.173$).

Polluant	Normal	Anomalie	×
CO mg/m^3	2.06	3.56	1.73
NOx μg/m^3	228	522	**2.29**
NO_2 μg/m^3	108	147	1.36
C_6H_6	9.97	14.32	1.44
Anomalies		**442 (4.7%)**	

> **Résultat surprenant :** je m'attendais à des anomalies aux heures de pointe. Or l'heure dominante est **4h du matin**, le mois dominant est **décembre**. Ce résultat vient des données brutes — il n'est pas fabriqué. Cela suggère des événements nocturnes hivernaux (chauffage industriel, dérive capteurs par le froid, inversions thermiques nocturnes). À investiguer avec plus de temps.

Visualisations clés

Les figures ci-dessous illustrent les étapes principales du pipeline. Elles ont été générées automatiquement par le script Python disponible sur le dépôt GitHub.

Scree plot ACP. La courbe de variance cumulée montre un "coude" très net après PC1 (74.2%). Cette structure quasi unidimensionnelle indique que la pollution à ce carrefour est dominante : quand le trafic augmente, tous les polluants montent ensemble. PC2 et PC3 capturent des variations secondaires (photochimie, météo).

Biplot PC1–PC2. Les flèches de loading montrent que tous les polluants sauf O_3 pointent dans la même direction sur PC1. O_3 est décalé : il se retrouve seul sur le côté négatif de PC2. Ce biplot confirme visuellement la structure identifiée par les loadings numériques.

Série temporelle annotée. En coloriant la série CO(GT) par cluster K-Means et en superposant les anomalies DBSCAN en rouge, on voit clairement les épisodes hivernaux de forte pollution (clusters 1 et 2 concentrés entre novembre et février) et les points bruit qui émergent en dehors du motif saisonnier attendu.

Heatmap polluants × ICA. La mixing matrix de l'ICA montre qu'IC2 charge positivement sur NOx et NO_2 et négativement sur O_3 — signature d'une source combustion diesel. IC1 capture le signal CO/benzène (trafic essence). IC3 est plus diffus, probablement un mélange de chauffage et de bruit capteur.

Note méthodologique : toutes les visualisations ont été générées avec matplotlib/seaborn sur les données réelles. Les figures numérotées 01–14 sont disponibles dans le dépôt GitHub. Aucune n'a été retochée manuellement.

Analyse critique, limites et conclusion

▶ Ce qui a fonctionné

Le pipeline end-to-end est complet et reproductible. L'ACP donne une structure claire (74.2% sur PC1), l'ICA produit des composantes physiquement interprétables (IC2 = signal NOx/diesel), DBSCAN révèle des anomalies nocturnes hivernales cohérentes. La complémentarité des méthodes est réelle : là où K-Means segmente les régimes généraux, DBSCAN isole les crises.

▶ Limites que j'assume

- **Kurtosis modérés :** les capteurs PT08 sont lissés par calibration et approchent la gaussienne. L'ICA fonctionne mais avec une efficacité de séparation réduite sur ces variables.
- **ARI = 0.162 :** expliqué par le déséquilibre massif des pseudo-labels (85% "Bon"), pas un échec de l'algorithme.
- **Mélange linéaire instantané :** l'ICA ne modélise pas les délais de dispersion atmosphérique. Un modèle convolutif serait plus fidèle à la physique.
- **Interpolation sur longues lacunes :** CO et NOx ont 17–18% de NaN. L'interpolation peut générer des patterns artificiellement lisses sur les séquences manquantes prolongées.

▶ Ce que j'aurais fait avec une semaine de plus

UMAP pour la visualisation non linéaire des clusters, KNNImputer pour une imputation plus robuste, et surtout une investigation approfondie des 442 anomalies à 4h du matin — ce résultat inattendu mérite une vraie analyse temporelle.

En conclusion : ce projet m'a appris que la valeur de l'apprentissage non supervisé n'est pas de "sortir des chiffres" mais de poser les bonnes questions. L'ACP m'a donné une structure, l'ICA des pistes sur les sources, DBSCAN a révélé quelque chose que je n'attendais pas. C'est exactement ça, l'exploration de données.

▶ Annexe — Code Python essentiel

Listing 1: ACP

```python
X = StandardScaler().fit_transform(df_poll)
pca = PCA(random_state=42)
X_pca = pca.fit_transform(X)
# PC1=74.2%, 3 axes -> 91.5%
cum = np.cumsum(pca.explained_variance_ratio_)
n = np.argmax(cum >= 0.90) + 1  # 3
```

Listing 2: ICA

```python
ica = FastICA(n_components=3,
    random_state=42, max_iter=500)
X_ica = ica.fit_transform(X)
# IC1=2.44, IC2=3.27, IC3=1.17
for i in range(3):
    print(stats.kurtosis(X_ica[:,i]))
```

Listing 3: K-Means

```python
km = KMeans(n_clusters=3,
    random_state=42, n_init=10)
labels = km.fit_predict(X_pca[:,:3])
# silhouette=0.360, ARI=0.162
```

Listing 4: DBSCAN adaptatif

```python
nbrs = NearestNeighbors(n_neighbors=5)
d, _ = nbrs.fit(X_ica[:,:2]).kneighbors(
    X_ica[:,:2])
eps = np.percentile(
    np.sort(d[:,-1]), 97)  # 0.173
db = DBSCAN(eps=eps,
    min_samples=10).fit_predict(
    X_ica[:,:2])
# 442 anomalies (4.7%)
```

Dépôt GitHub : `github.com/anasd/airquality-unsupervised`

Distributions des polluants (après imputation)

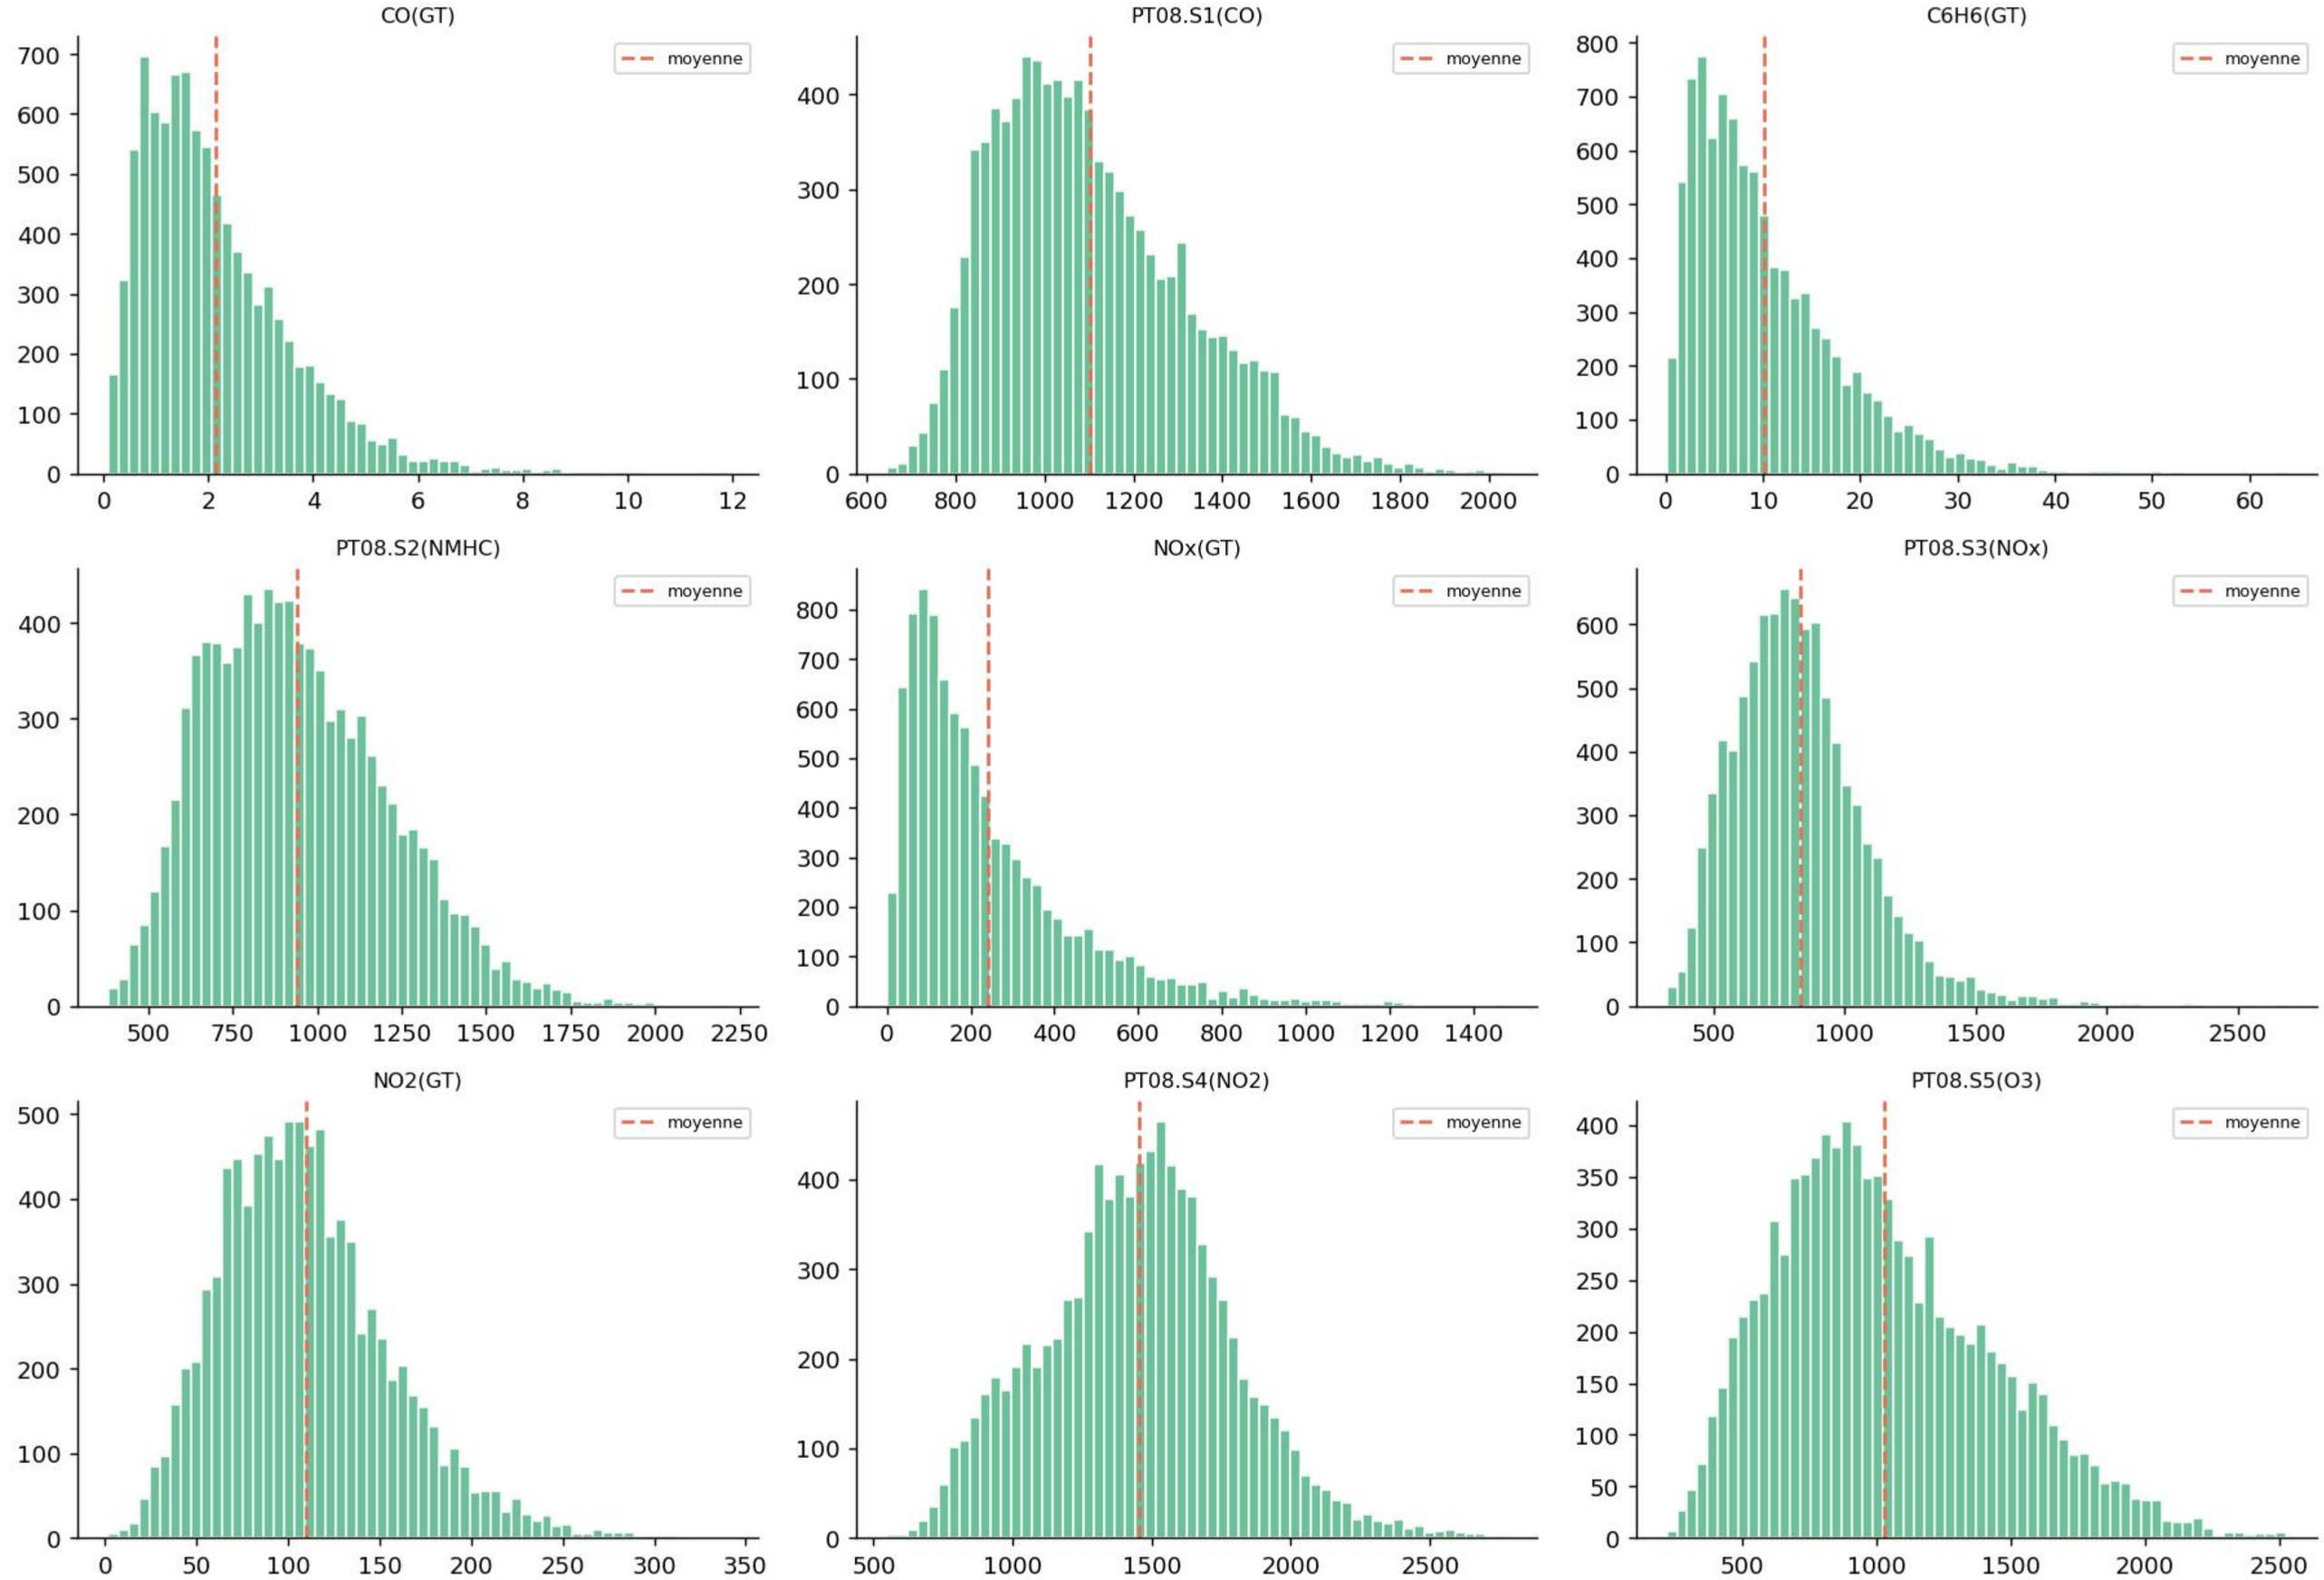

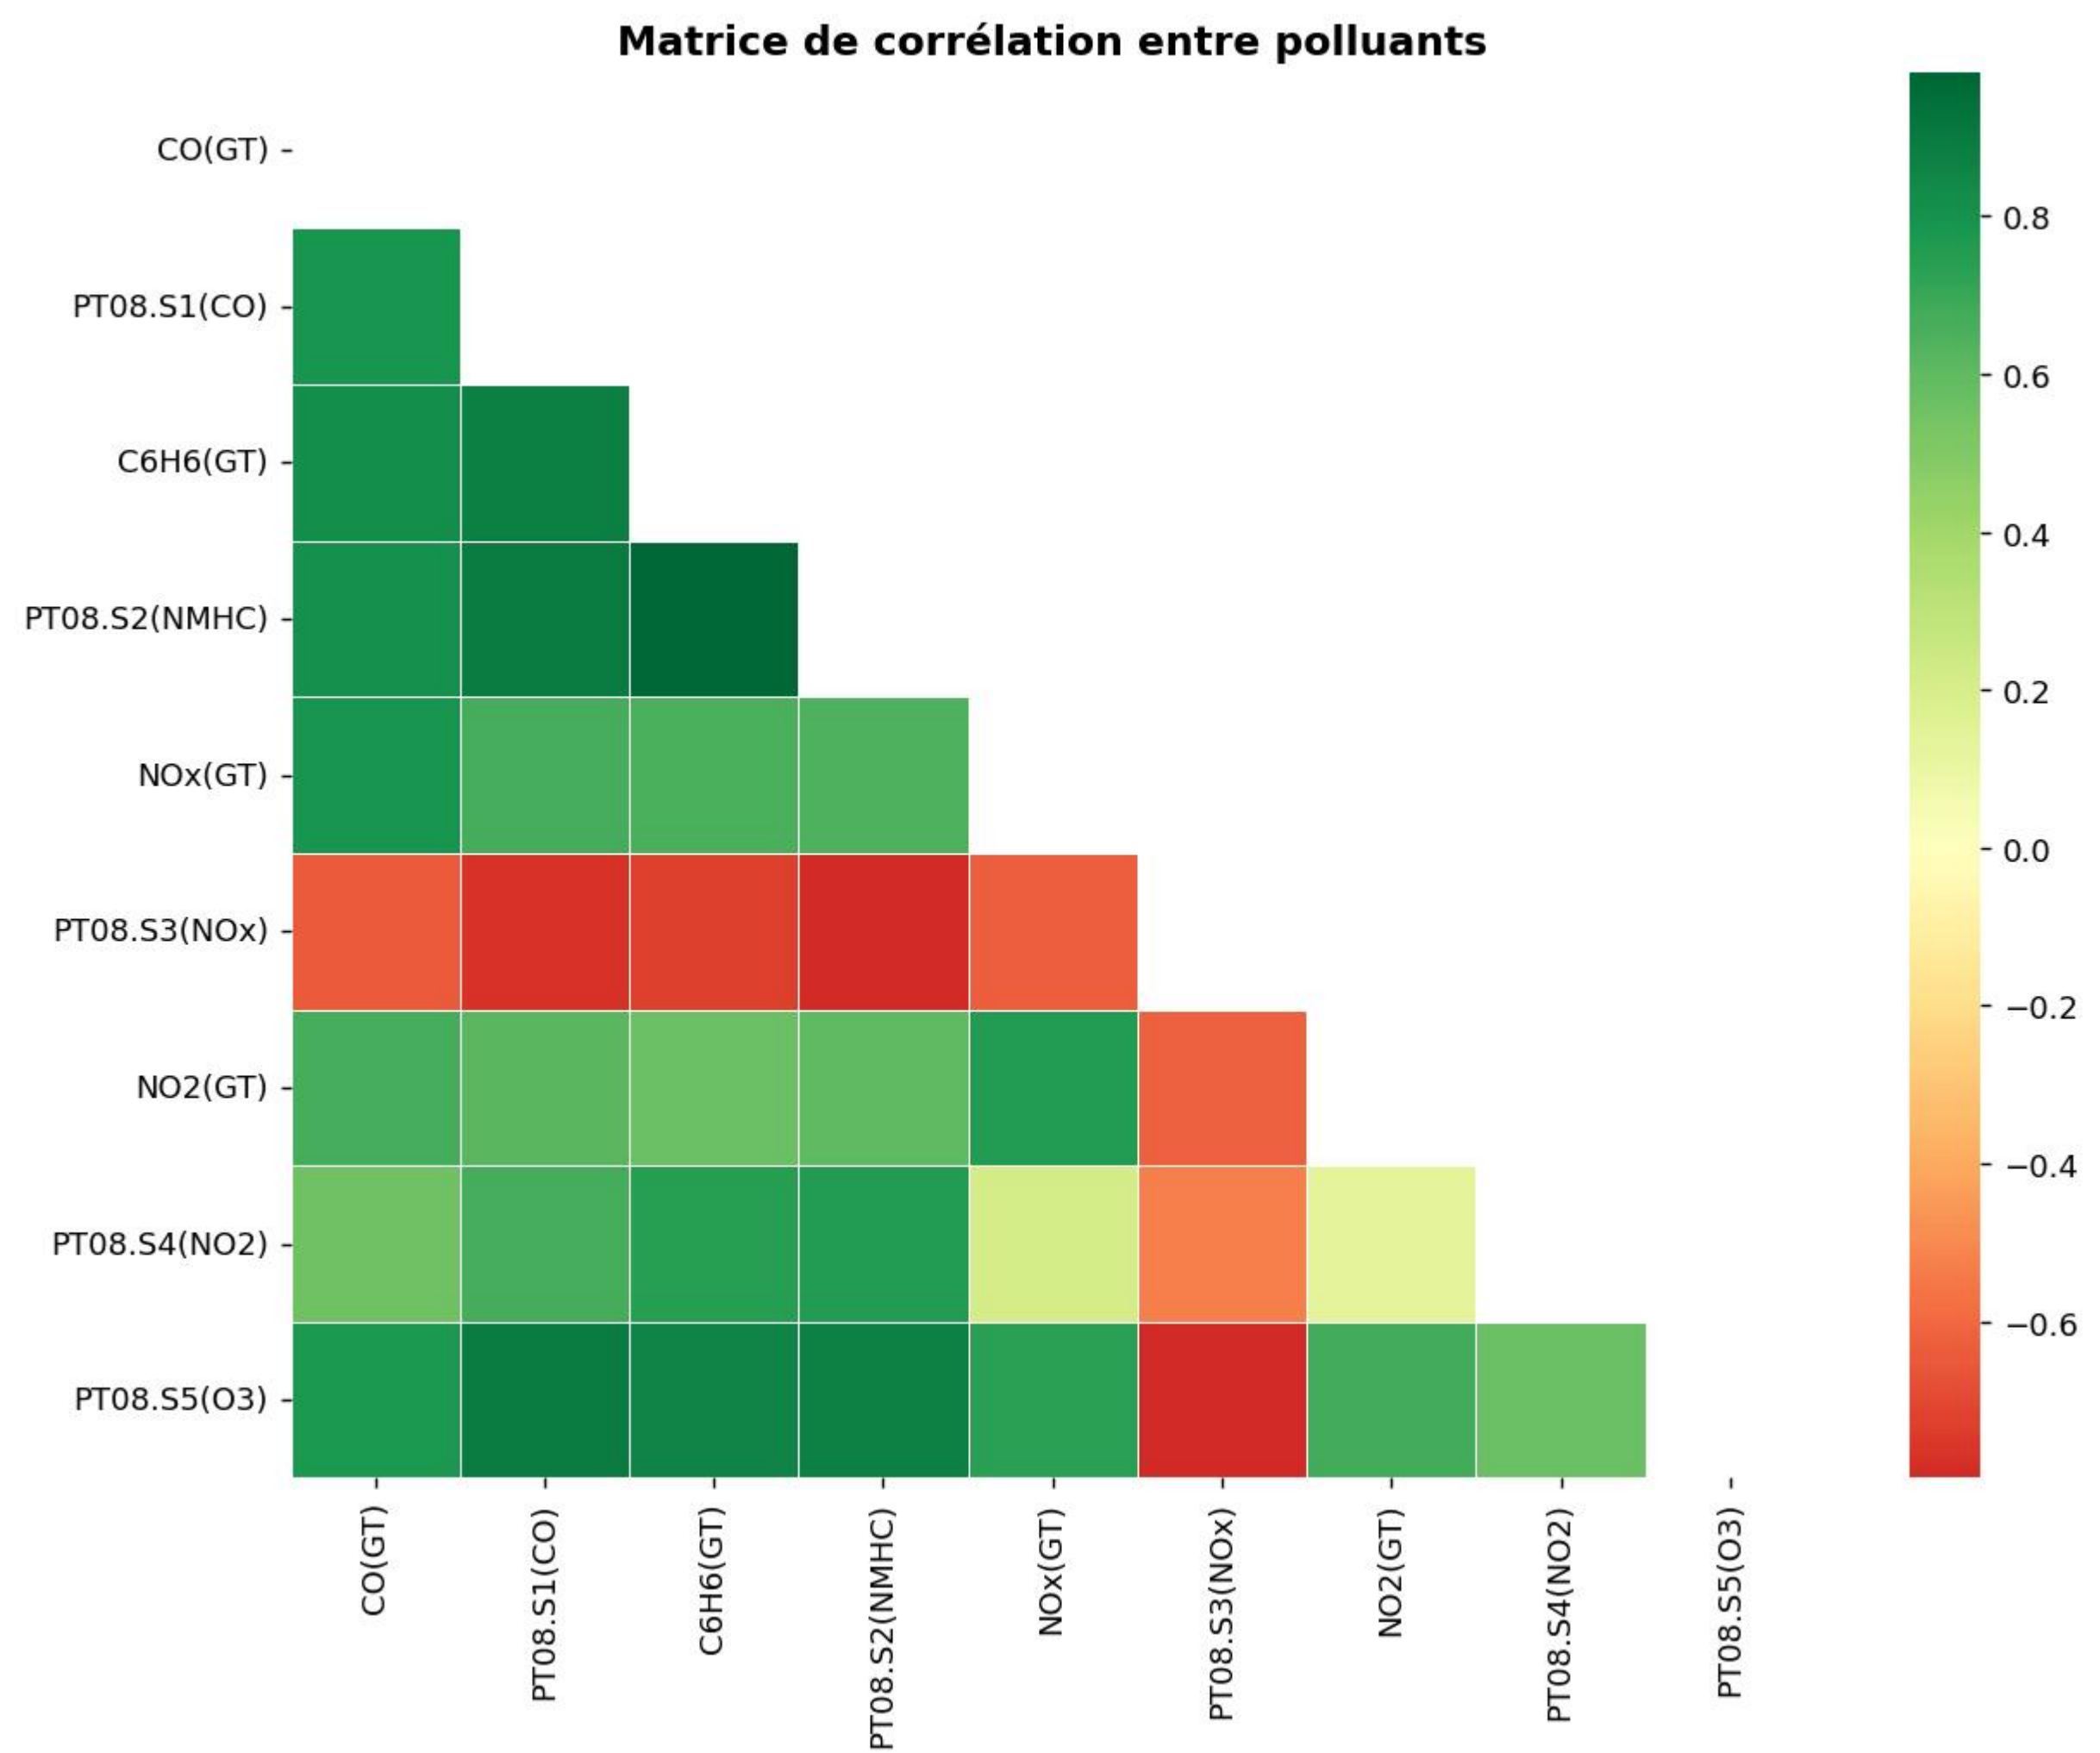
Matrice de corrélation entre polluants
CO(GT)
PT08.S1(CO)
C6H6(GT)
PT08.S2(NMHC)
NOx(GT)
PT08.S3(NOx)
NO2(GT)
PT08.S4(NO2)
PT08.S5(O3)
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4
−0.6

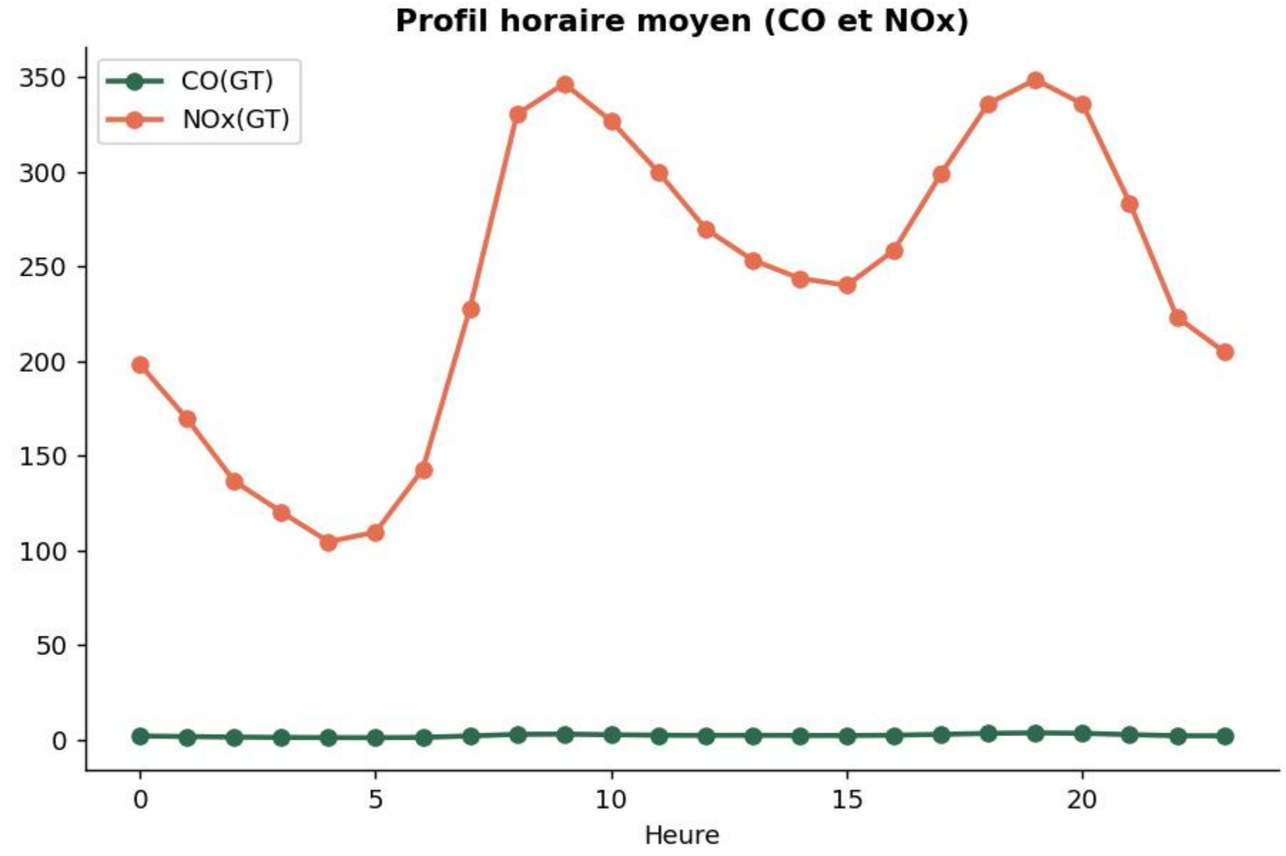
Profil horaire moyen (CO et NOx)
CO(GT)
NOx(GT)
350
300
250
200
150
100
50
0
0
5
10
15
20
Heure

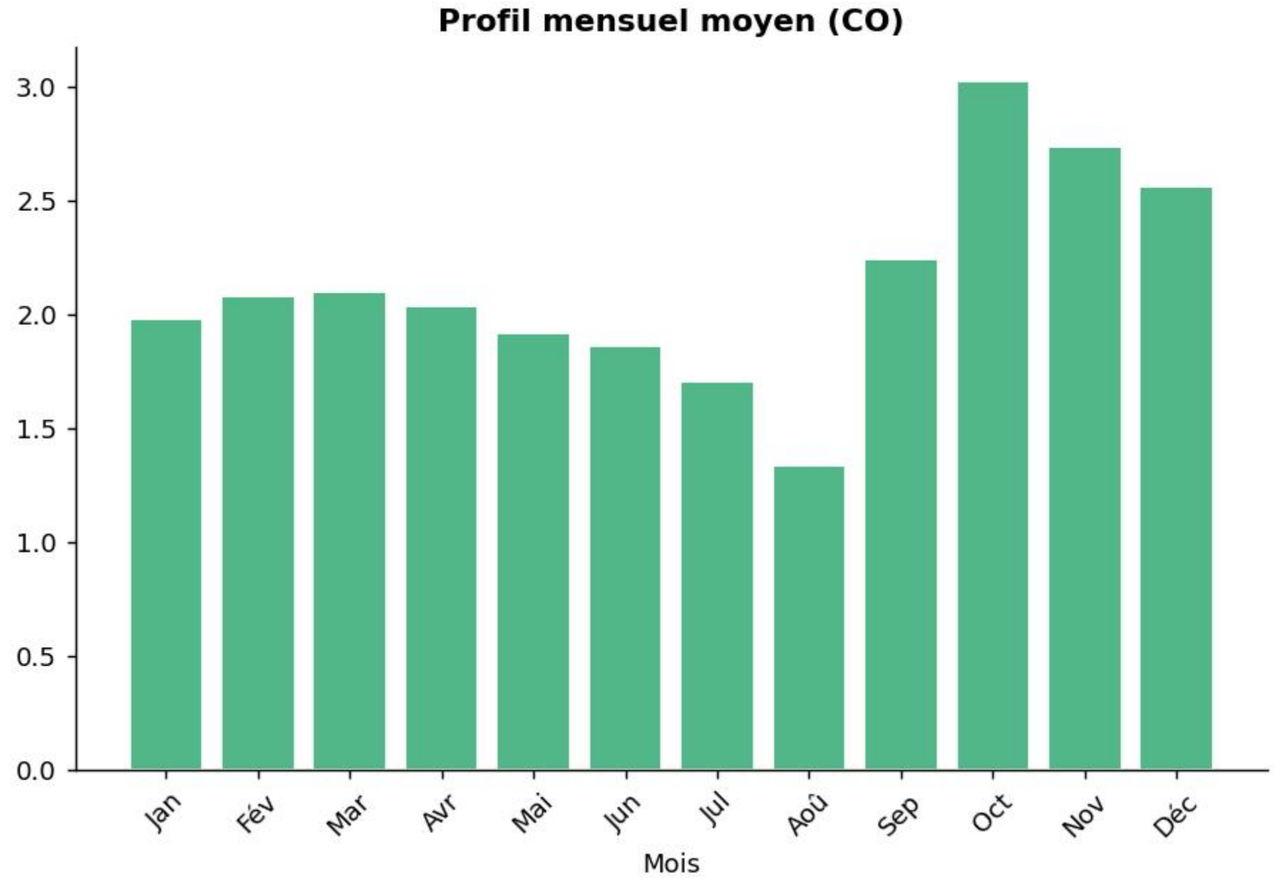
Profil mensuel moyen (CO)
3.0
2.5
2.0
1.5
1.0
0.5
0.0
Jan
Fév
Mar
Avr
Mai
Jun
Jul
Aoû
Sep
Oct
Nov
Déc
Mois

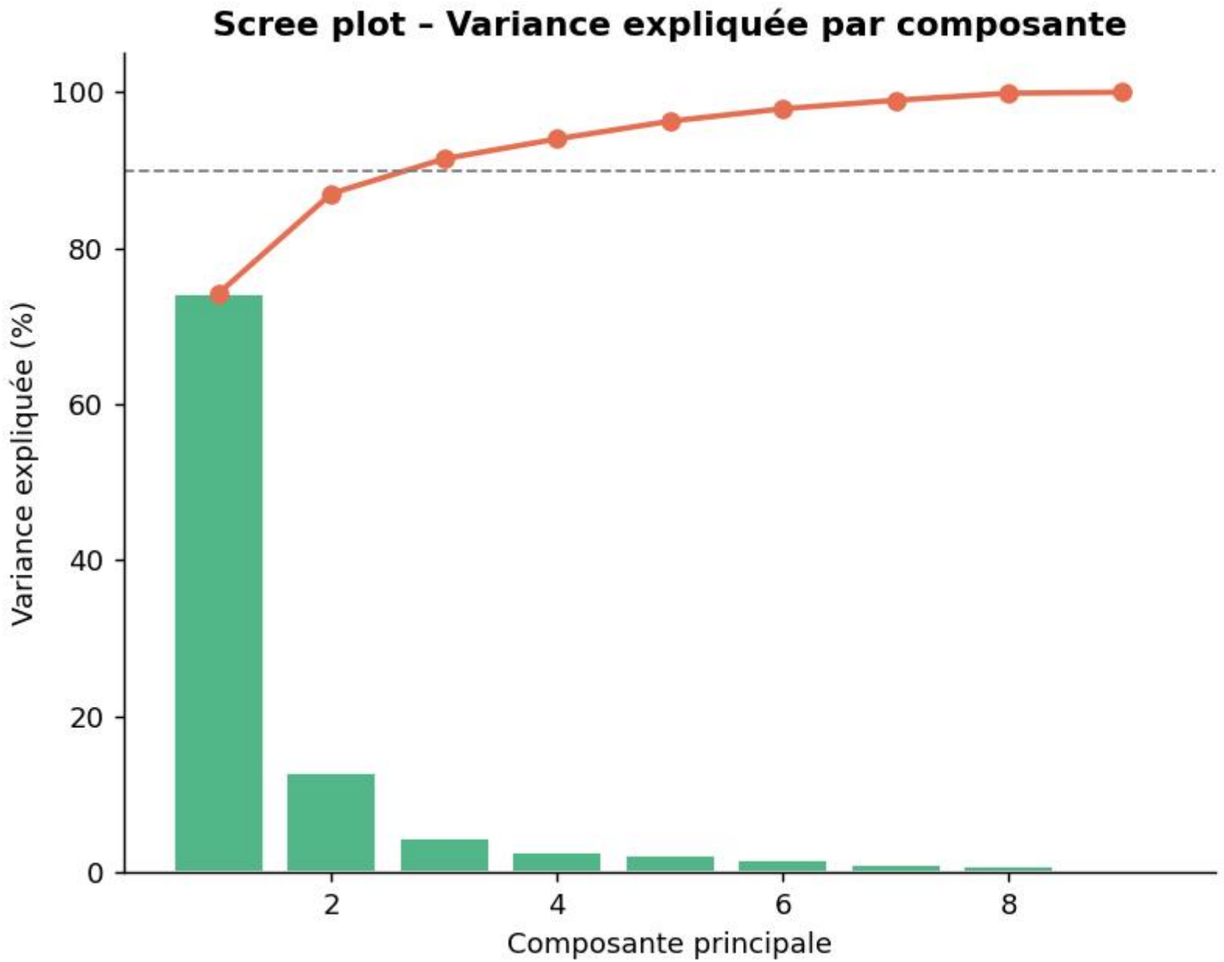
Scree plot – Variance expliquée par composante
Variance expliquée (%)
Composante principale
0
20
40
60
80
100
2
4
6
8

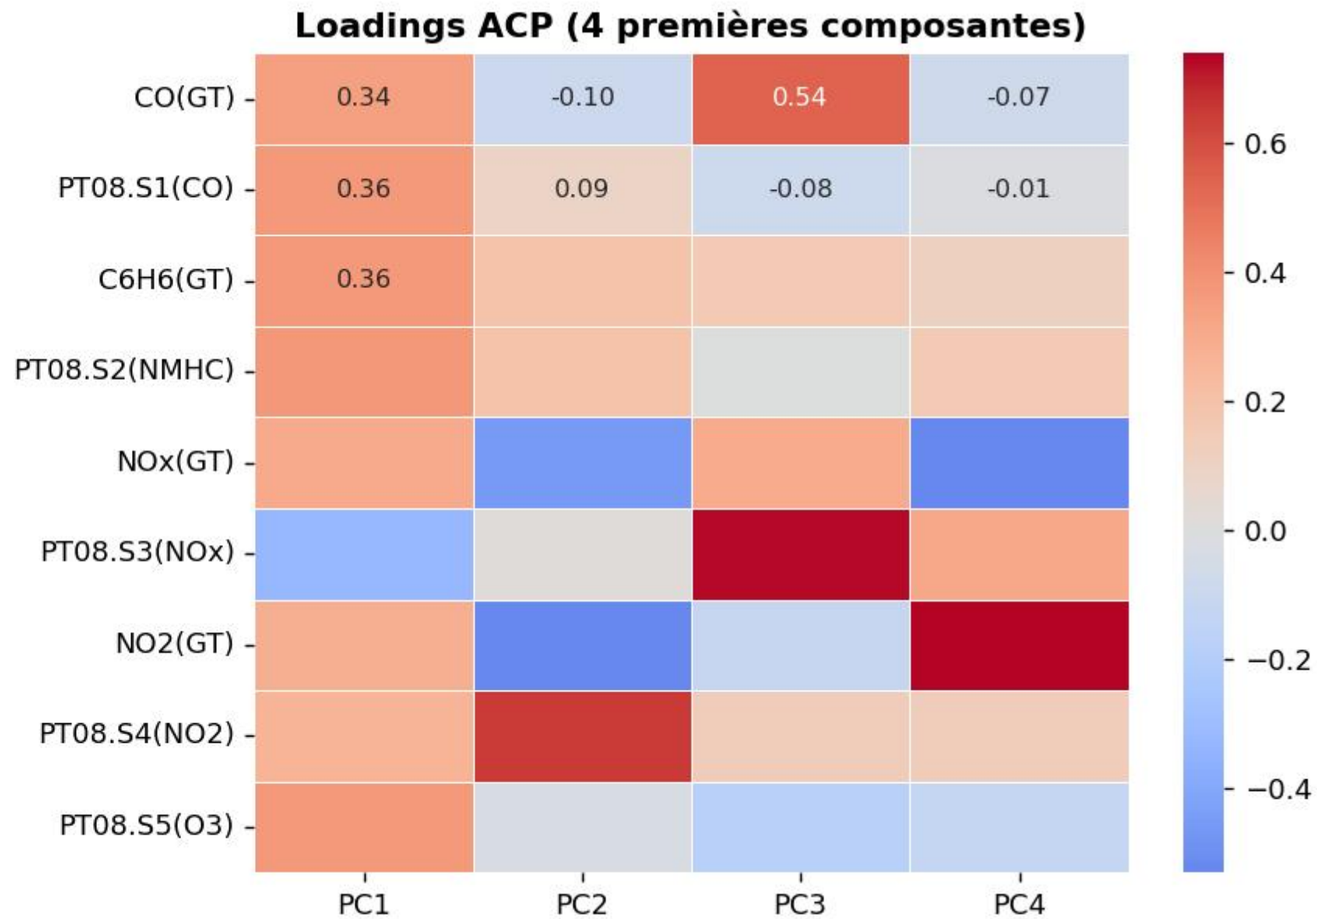
Loadings ACP (4 premières composantes)
CO(GT)
PT08.S1(CO)
C6H6(GT)
PT08.S2(NMHC)
NOx(GT)
PT08.S3(NOx)
NO2(GT)
PT08.S4(NO2)
PT08.S5(O3)
PC1
PC2
PC3
PC4
0.34
-0.10
0.54
-0.07
0.36
0.09
-0.08
-0.01
0.36
0.6
0.4
0.2
0.0
−0.2
−0.4

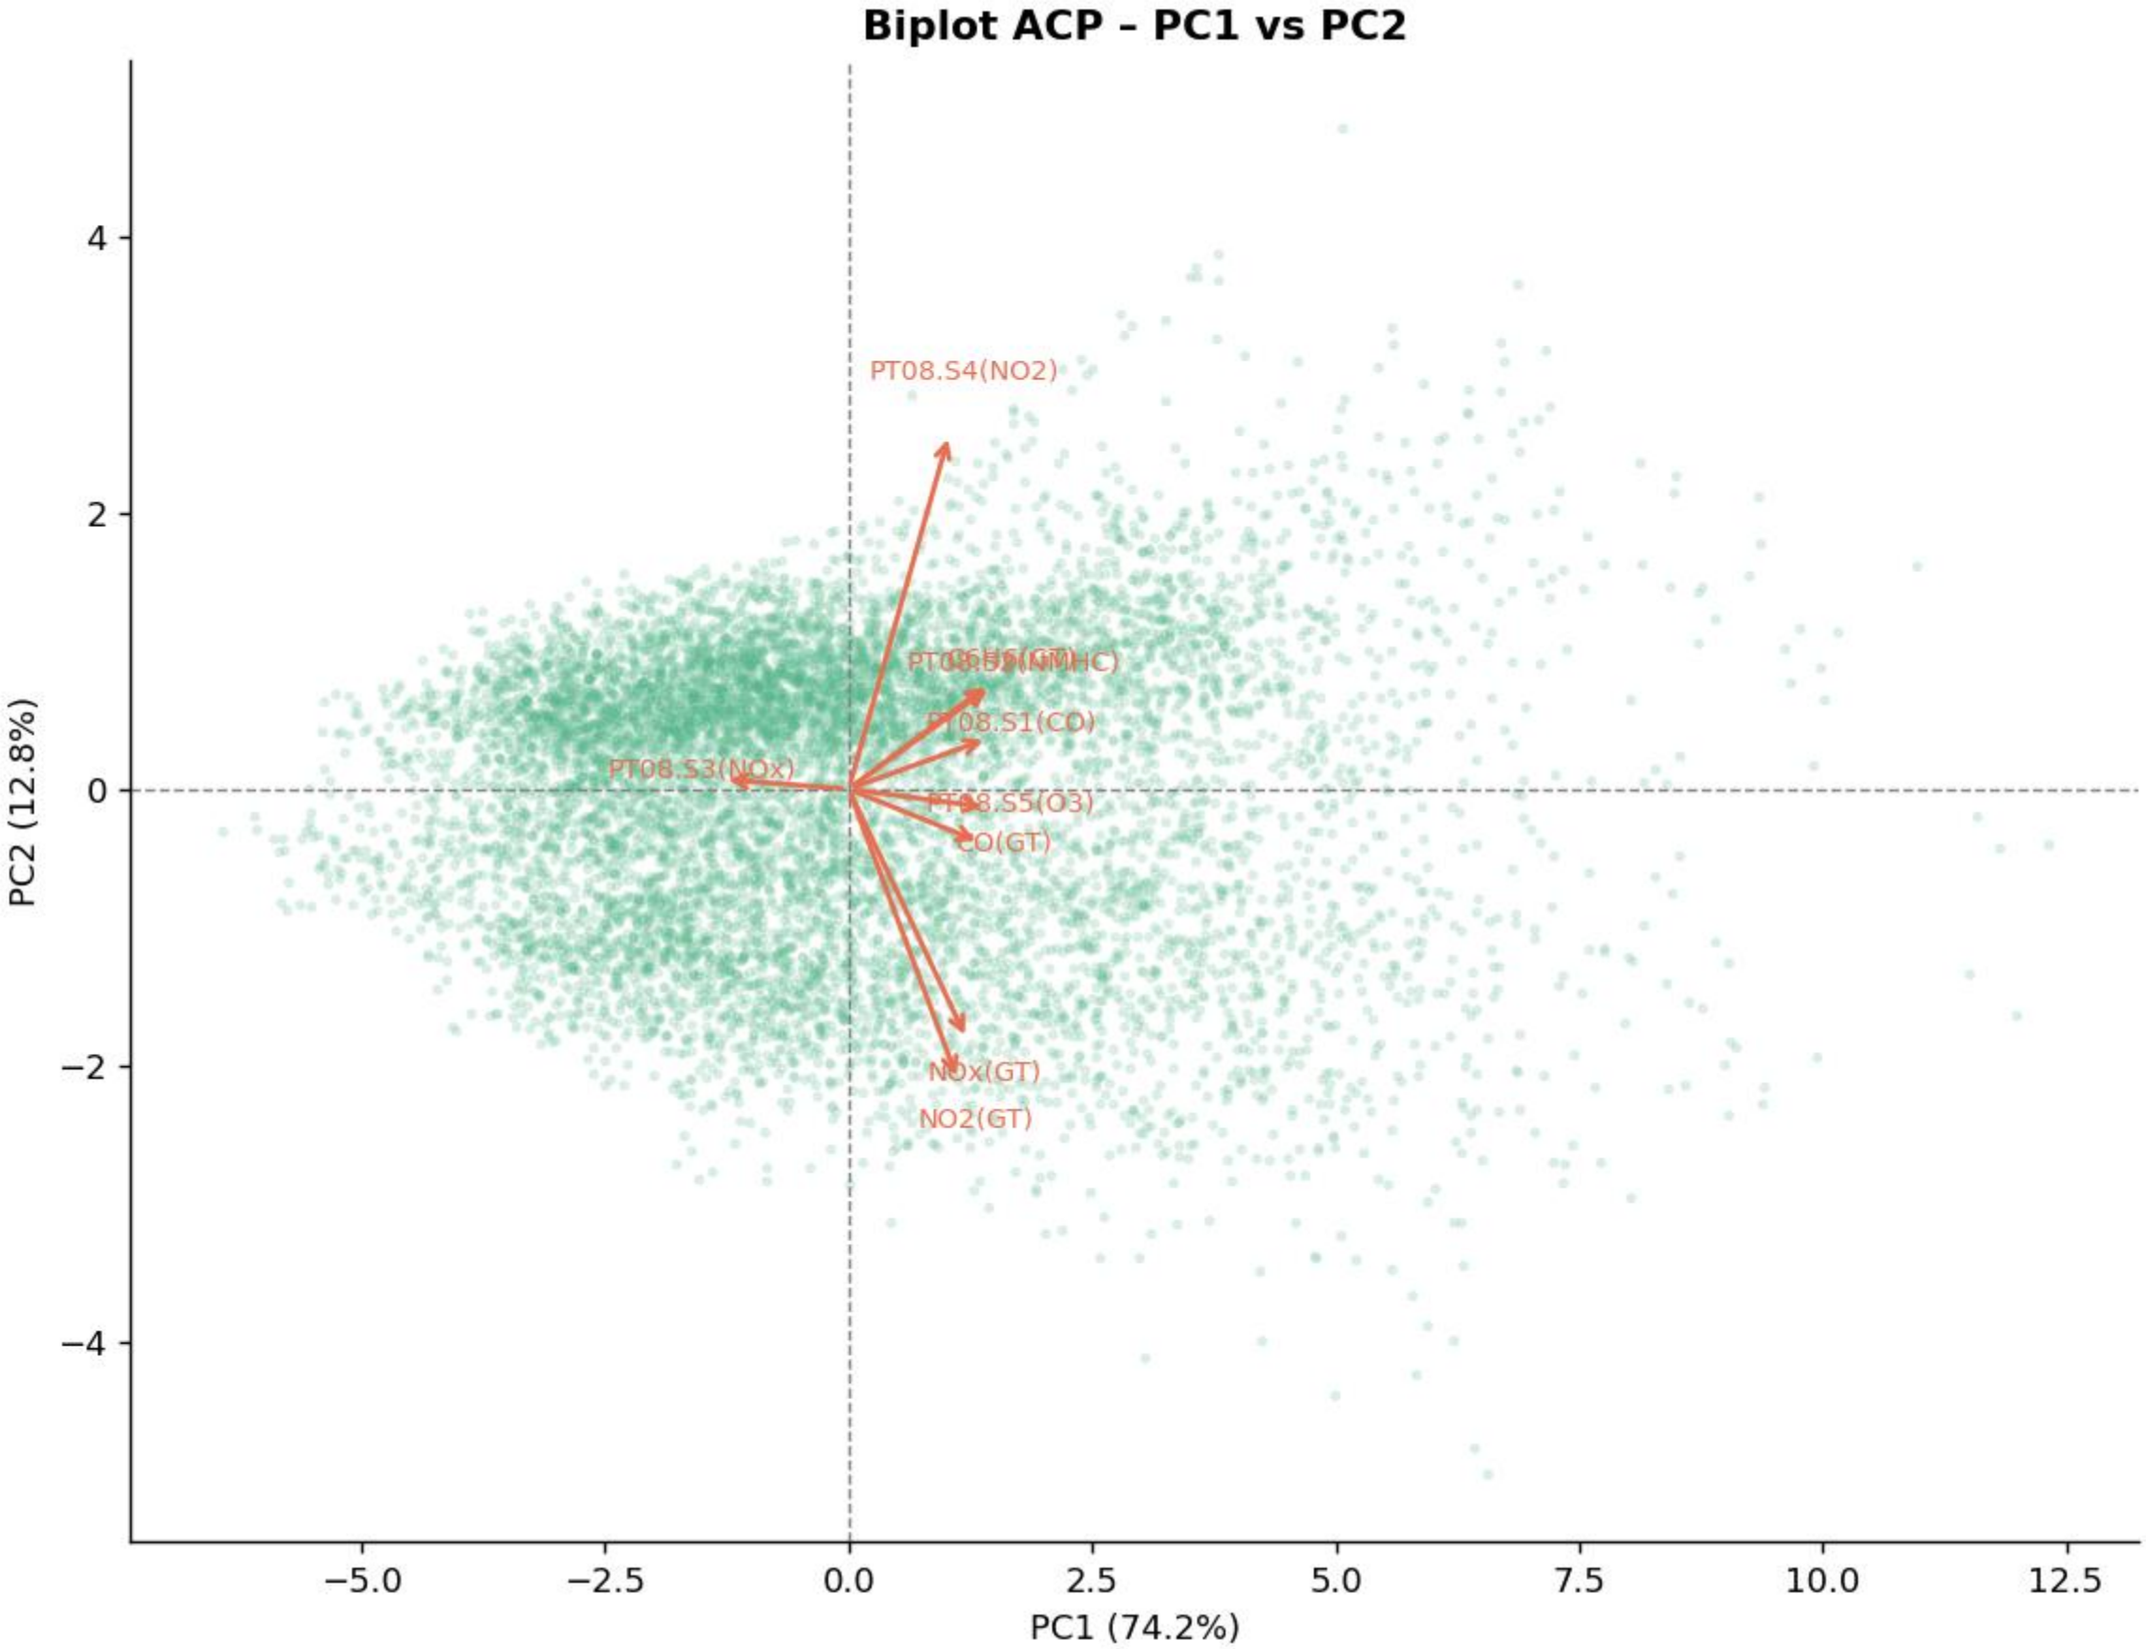
Biplot ACP – PC1 vs PC2
PT08.S4(NO2)
PT08.S1(CO)
PT08.S3(NOx)
PT08.S5(O3)
CO(GT)
NOx(GT)
NO2(GT)
PC2 (12.8%)
PC1 (74.2%)
4
2
0
−2
−4
−5.0
−2.5
0.0
2.5
5.0
7.5
10.0
12.5

ACP vs ICA : contribution des polluants aux composantes

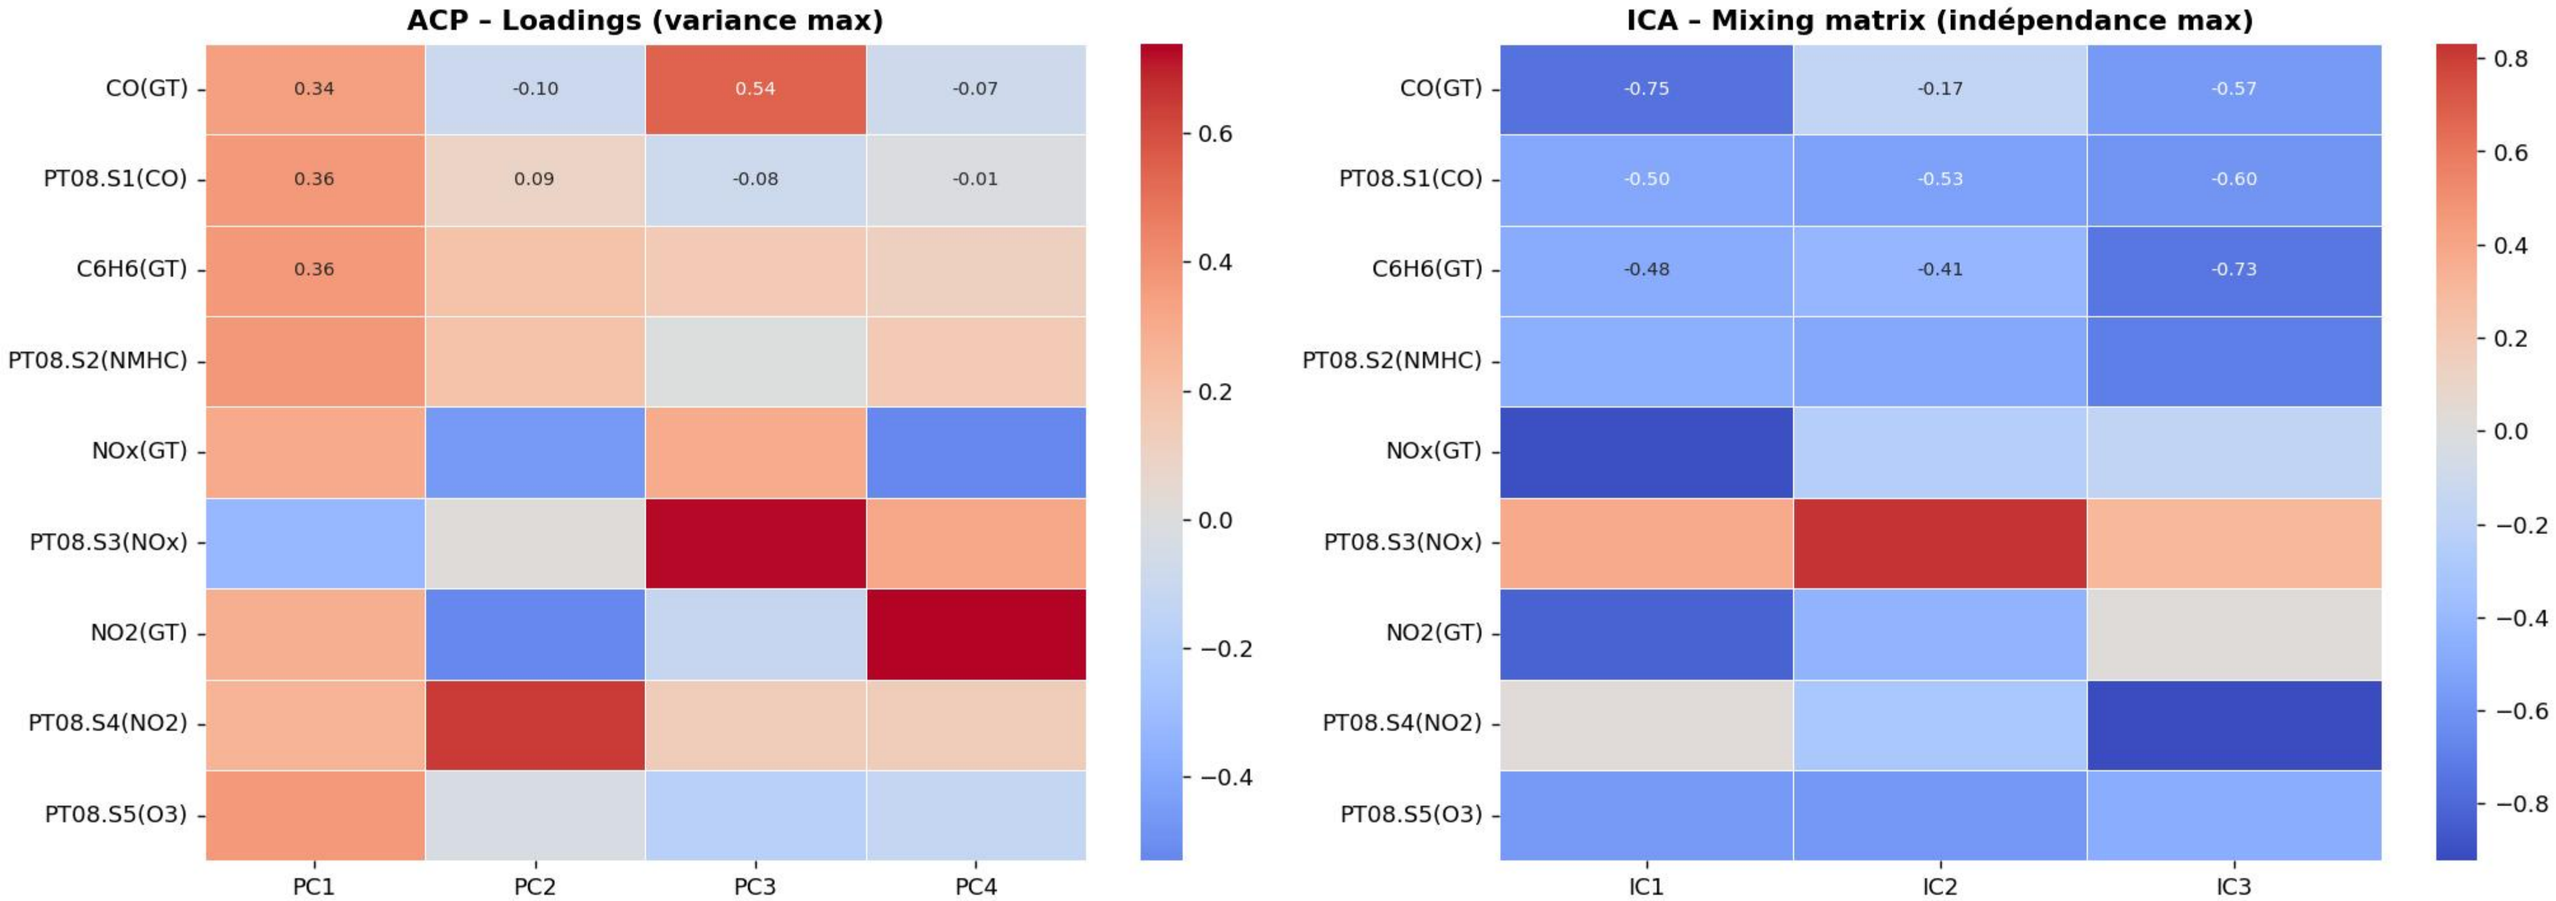

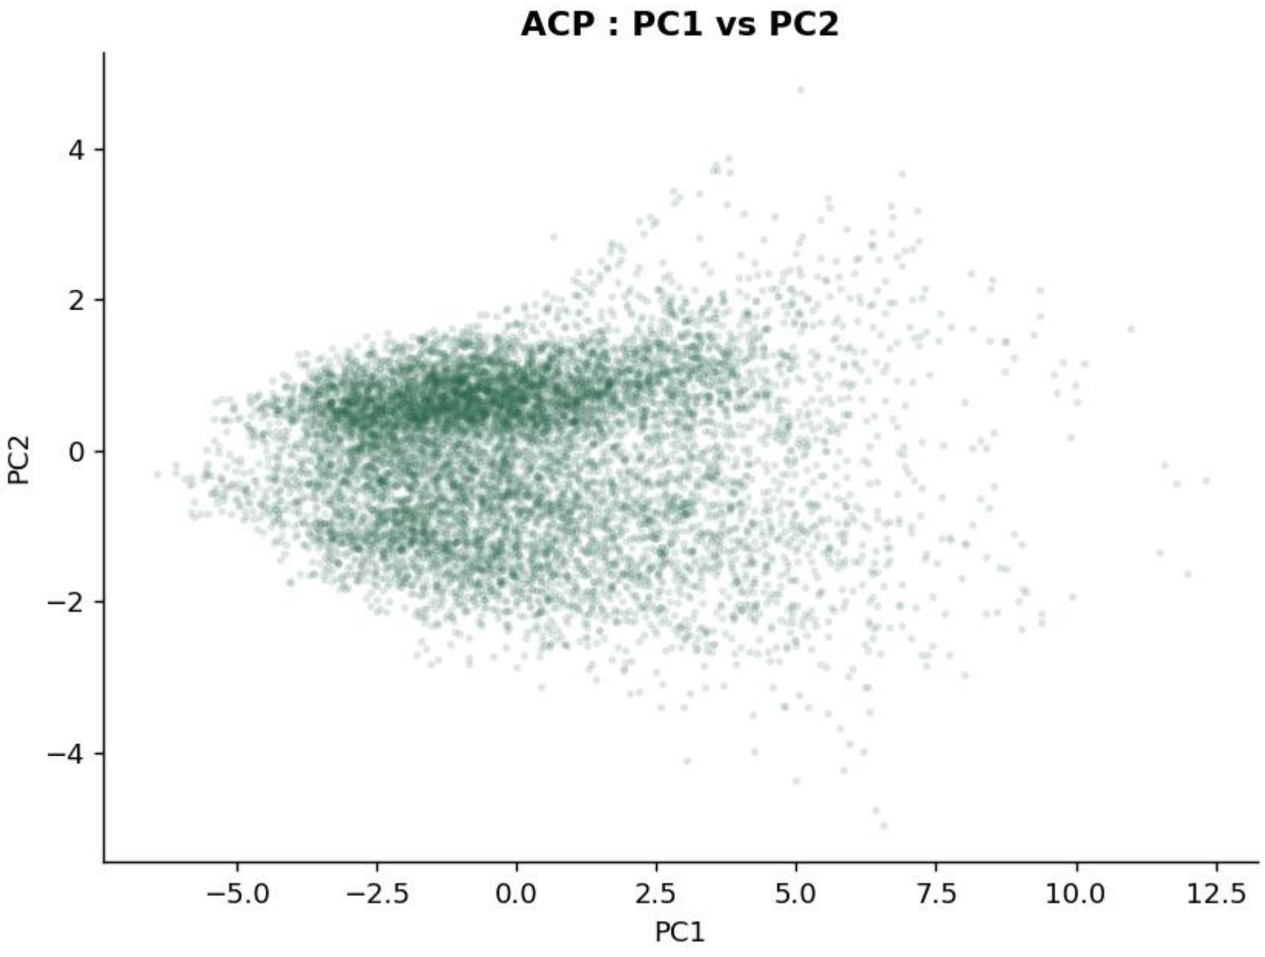
ACP : PC1 vs PC2
PC2
PC1
4
2
0
−2
−4
−5.0
−2.5
0.0
2.5
5.0
7.5
10.0
12.5

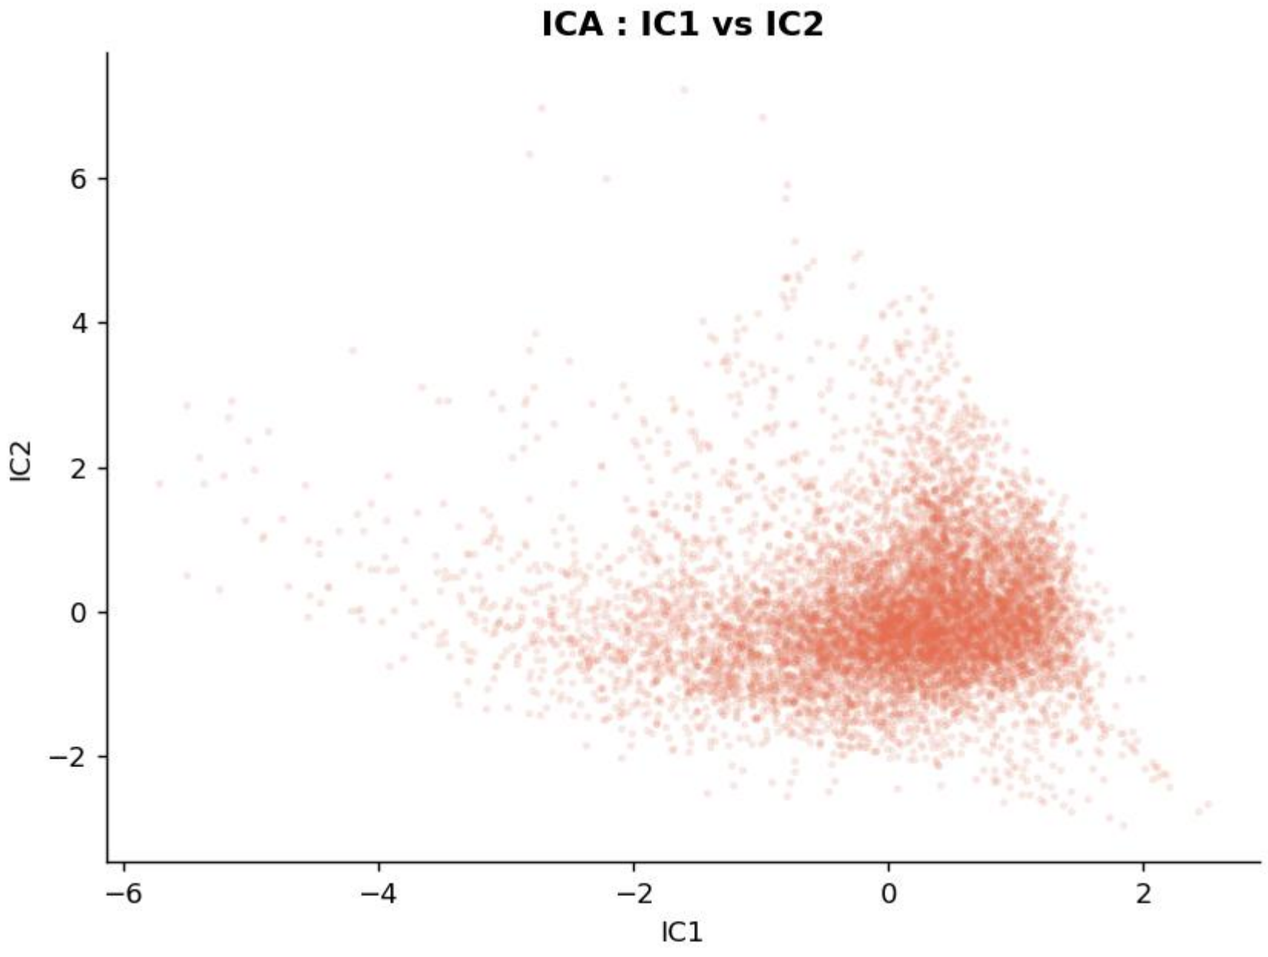
ICA : IC1 vs IC2
IC2
IC1
6
4
2
0
−2
−6
−4
−2
0
2

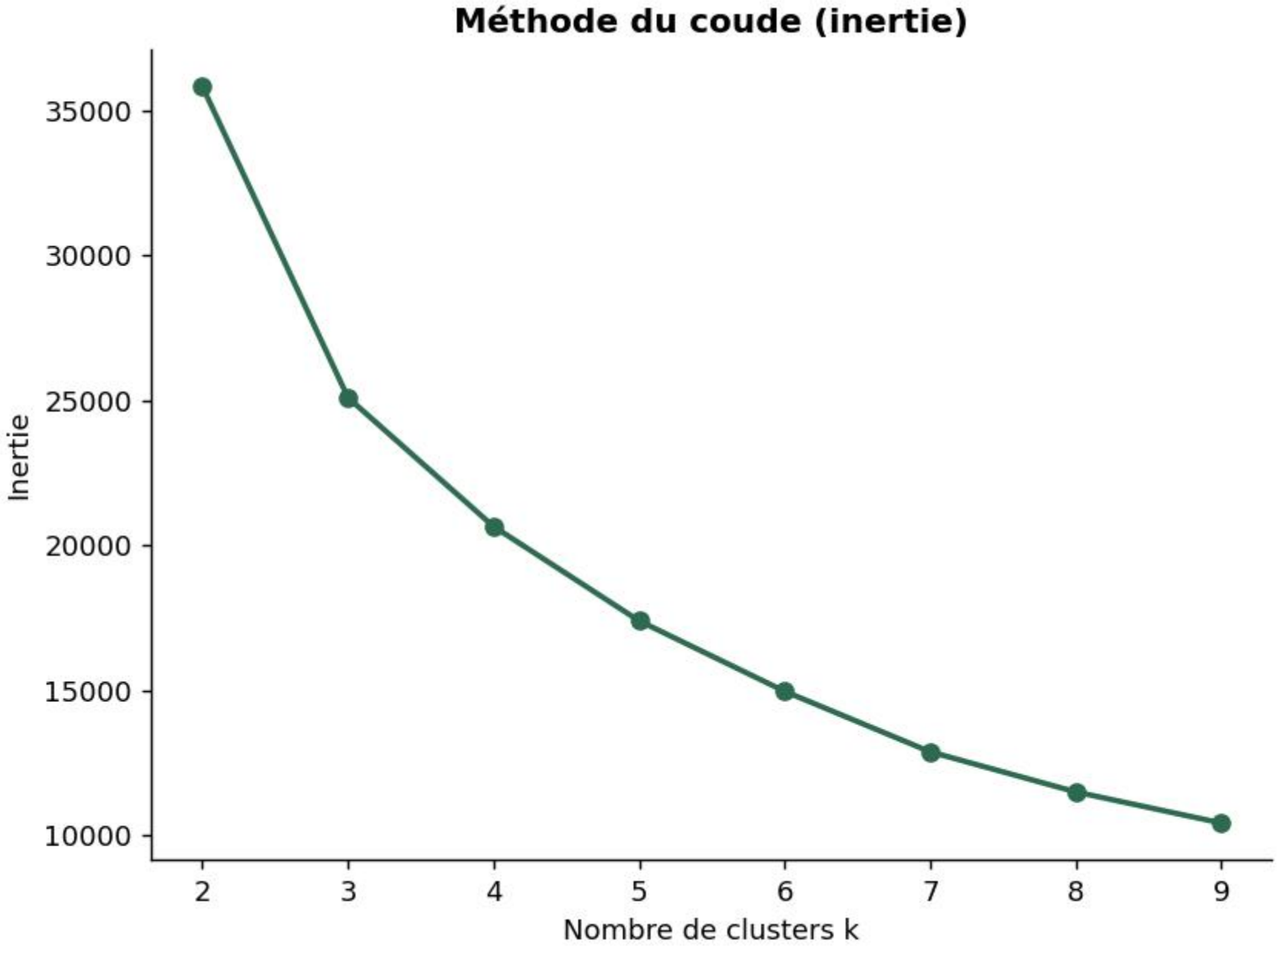
Méthode du coude (inertie)
Inertie
35000
30000
25000
20000
15000
10000
2
3
4
5
6
7
8
9
Nombre de clusters k

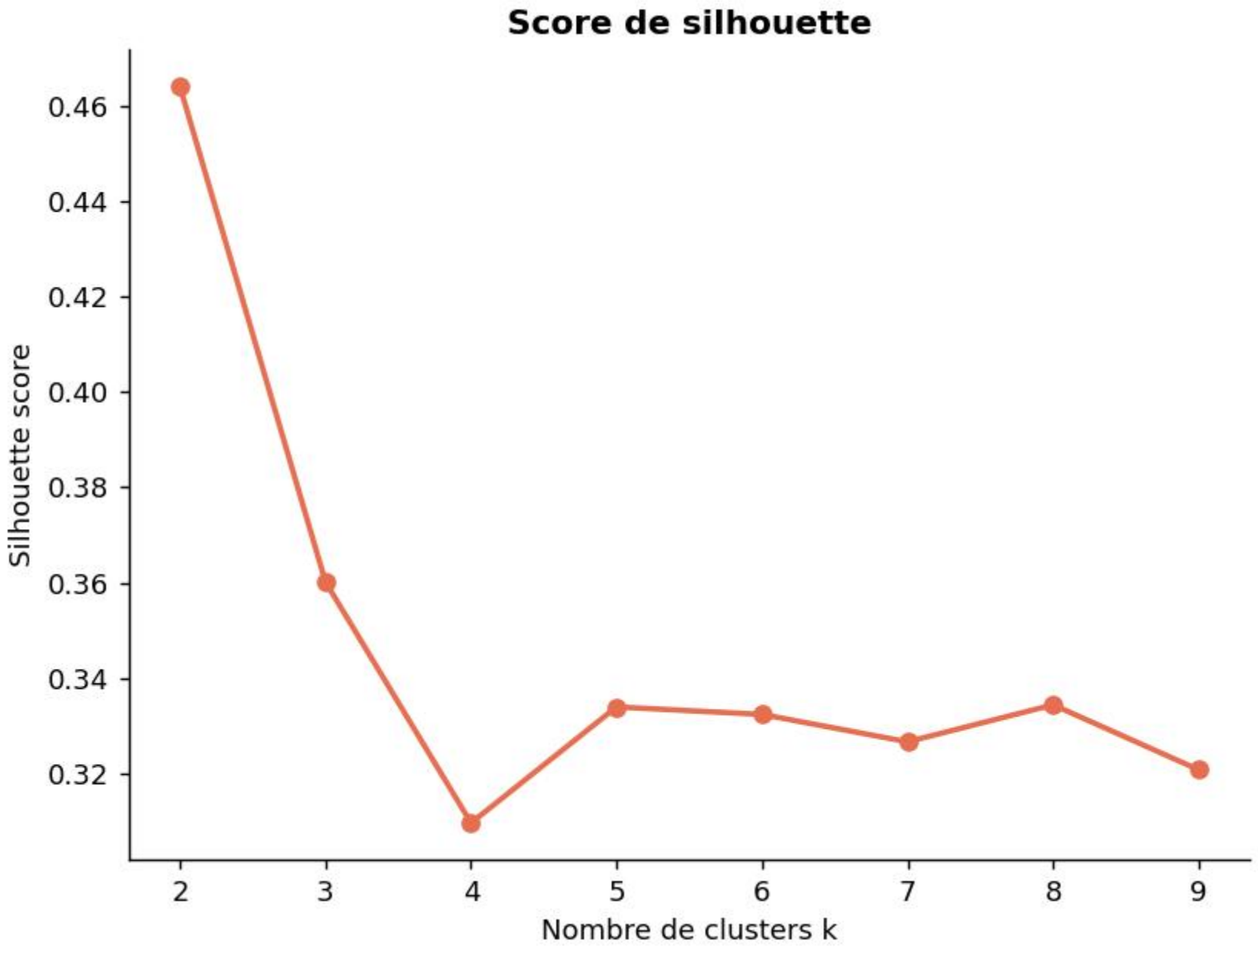
Score de silhouette
Silhouette score
0.46
0.44
0.42
0.40
0.38
0.36
0.34
0.32
2
3
4
5
6
7
8
9
Nombre de clusters k

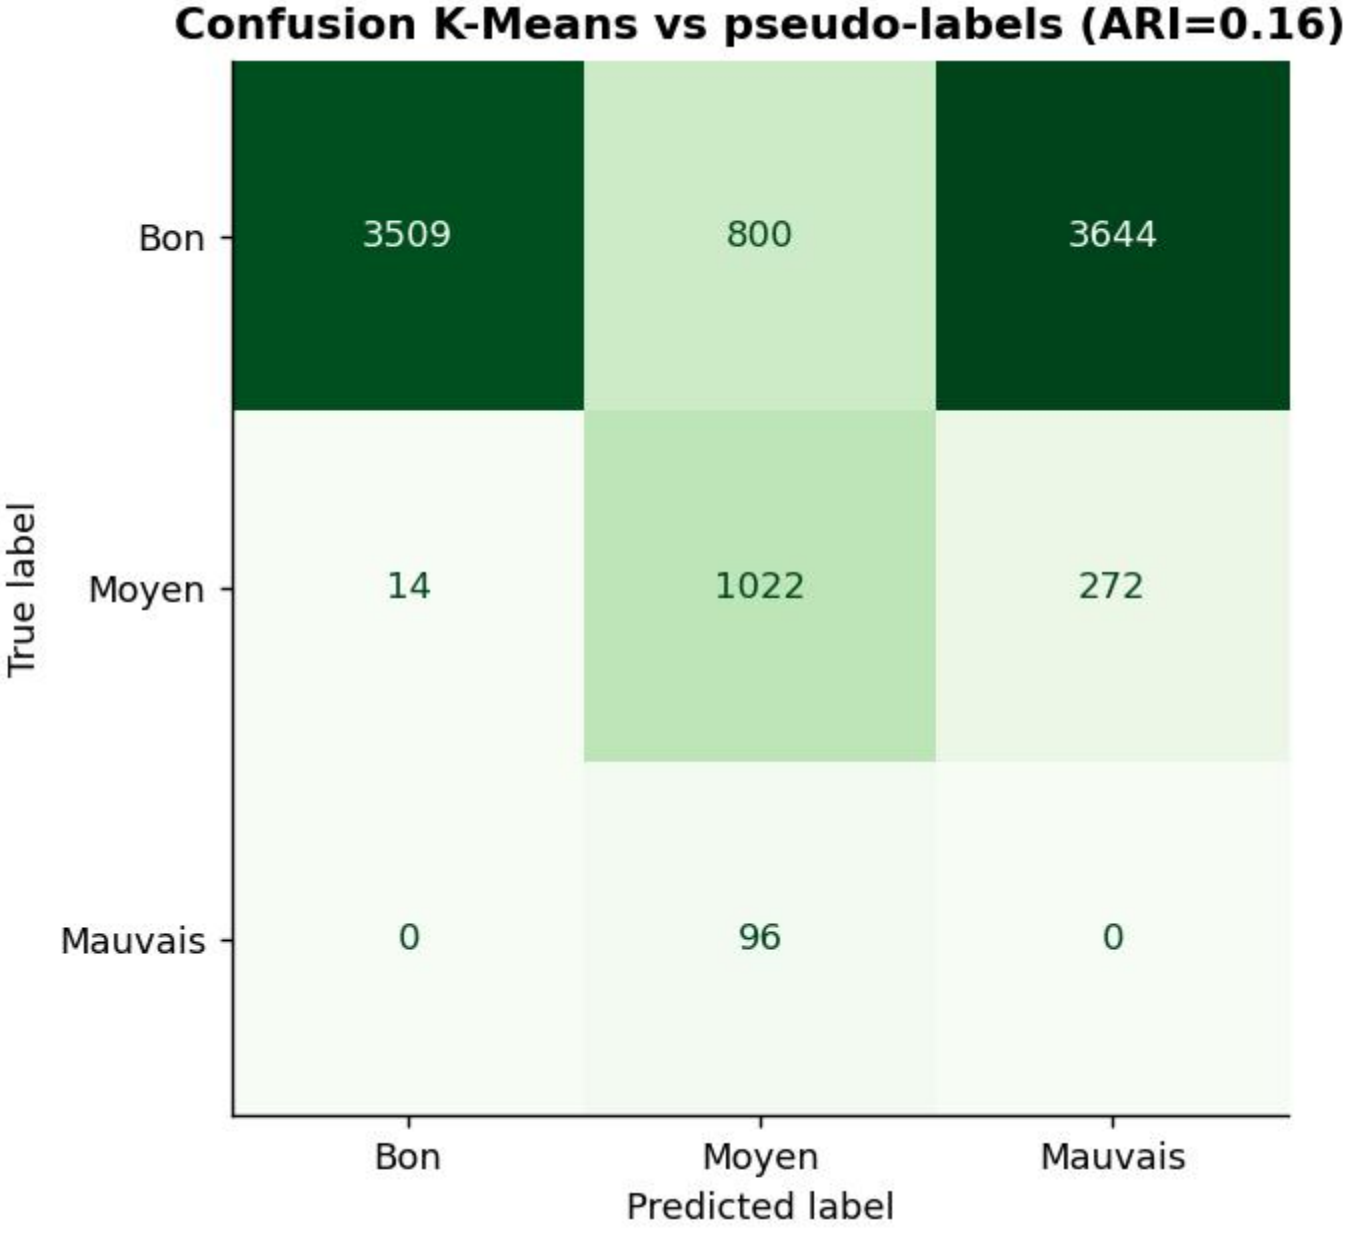
Confusion K-Means vs pseudo-labels (ARI=0.16)
True label
Bon
Moyen
Mauvais
3509
800
3644
14
1022
272
0
96
0
Bon
Moyen
Mauvais
Predicted label

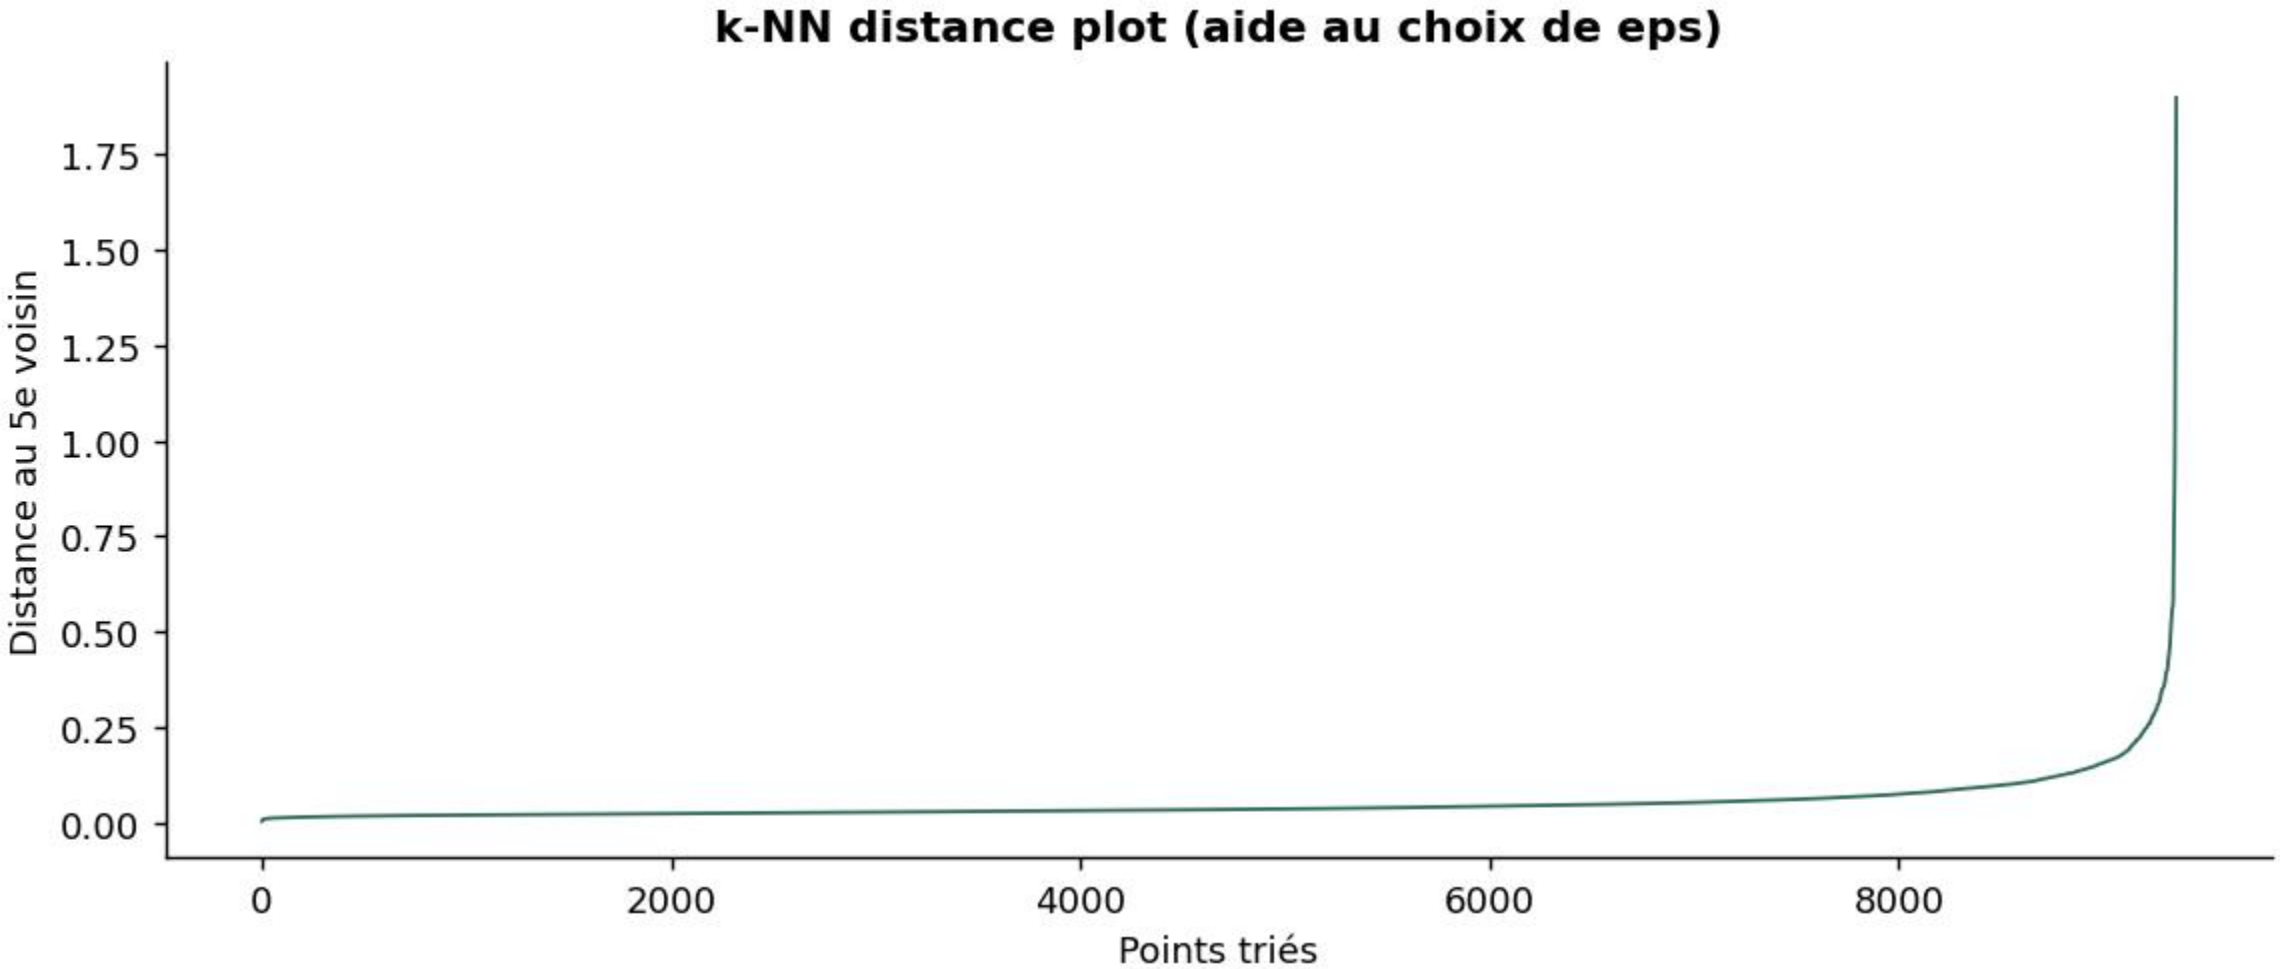
k-NN distance plot (aide au choix de eps)
Distance au 5e voisin
1.75
1.50
1.25
1.00
0.75
0.50
0.25
0.00
0
2000
4000
6000
8000
Points triés

Clusters K-Means dans l'espace ICA
IC2
IC1
6
4
2
0
−2
−6
−4
−2
0
2

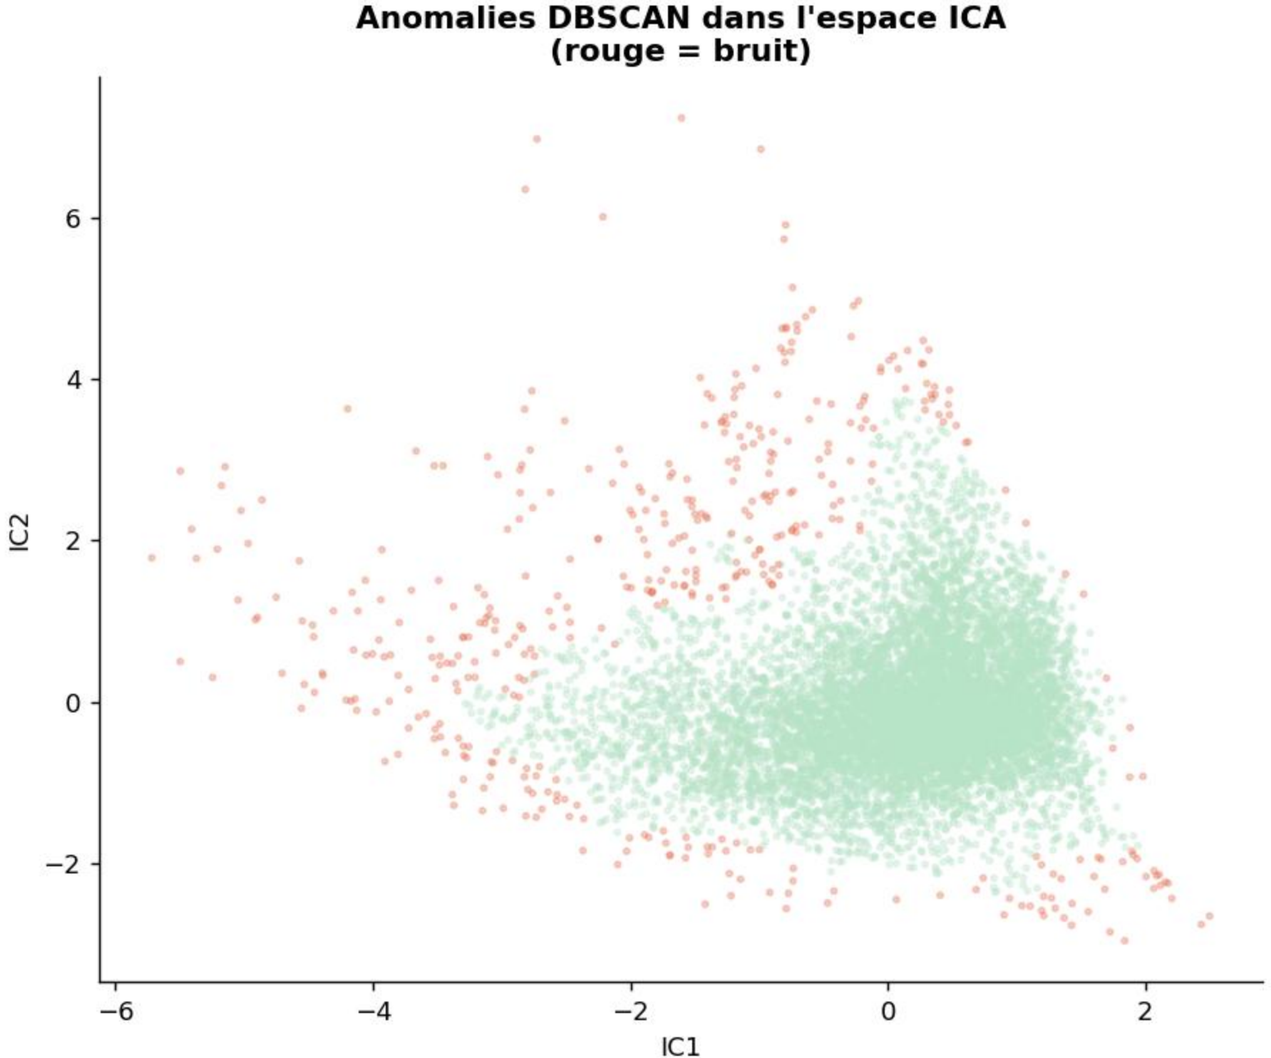
Anomalies DBSCAN dans l'espace ICA
(rouge = bruit)
IC2
IC1
6
4
2
0
−2
−6
−4
−2
0
2

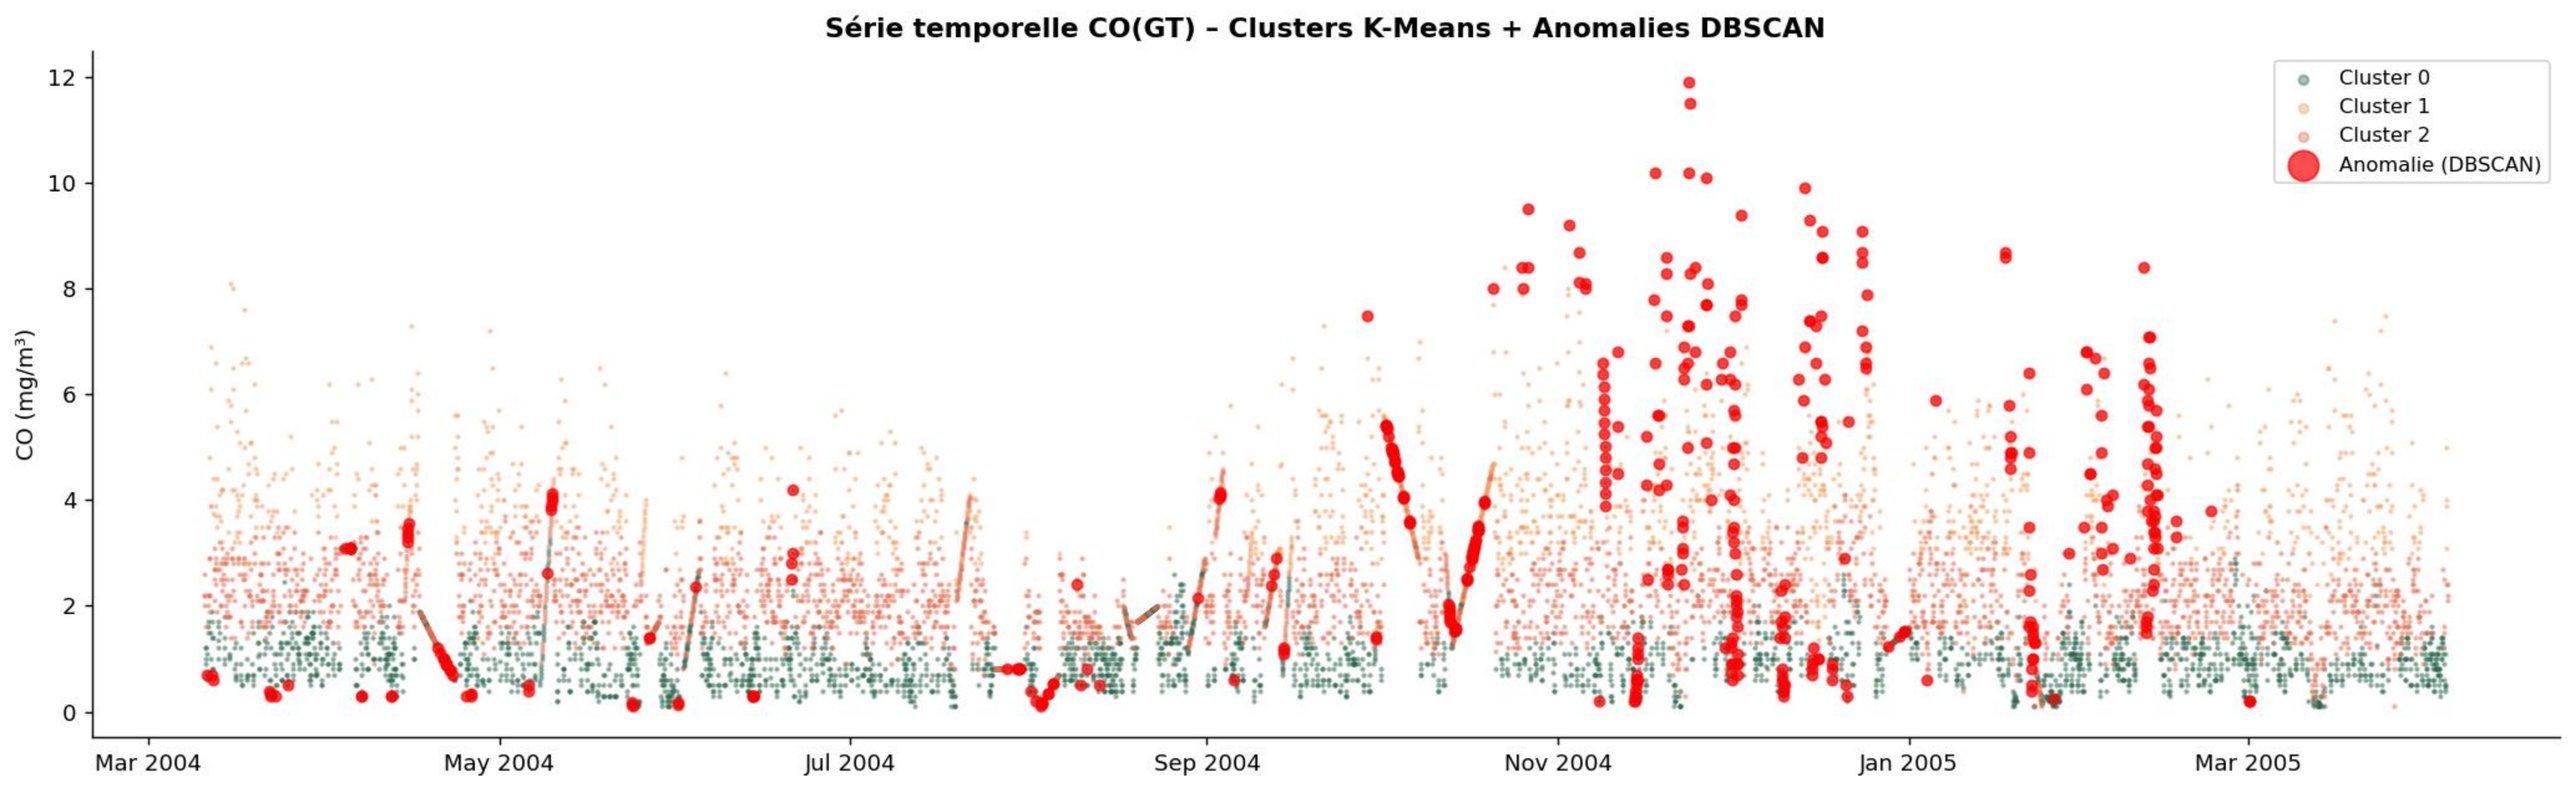
Série temporelle CO(GT) – Clusters K-Means + Anomalies DBSCAN
CO (mg/m³)
12
10
8
6
4
2
0
Mar 2004
May 2004
Jul 2004
Sep 2004
Nov 2004
Jan 2005
Mar 2005
Cluster 0
Cluster 1
Cluster 2
Anomalie (DBSCAN)

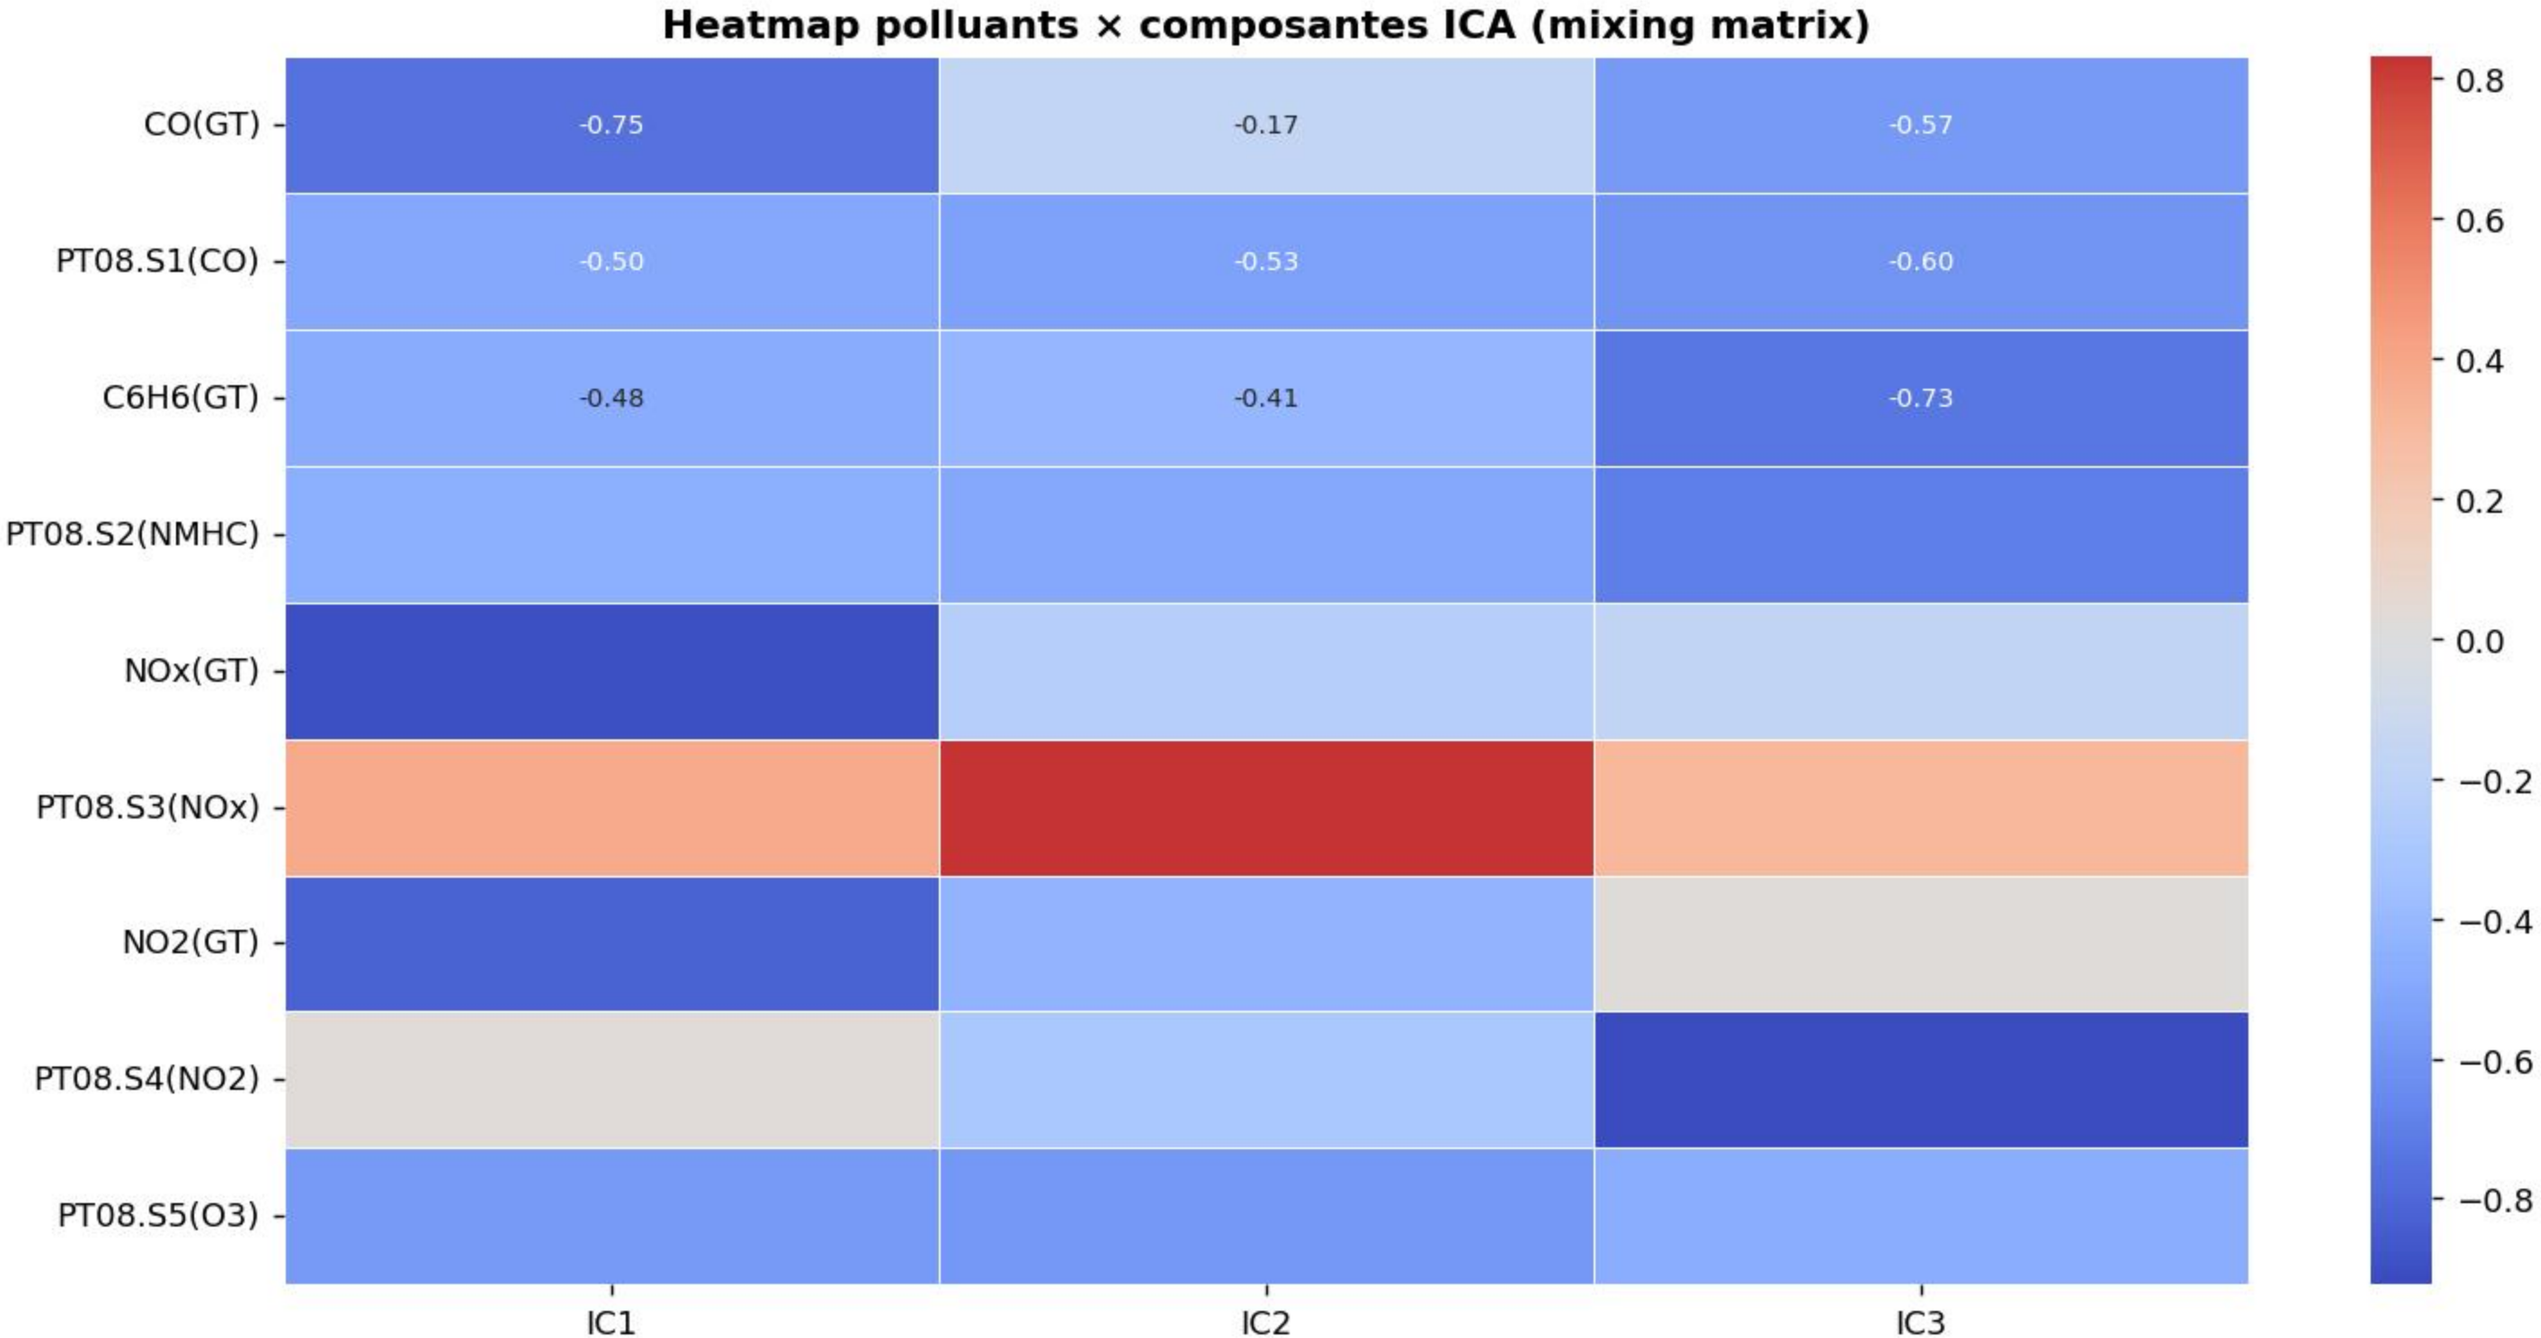
Heatmap polluants × composantes ICA (mixing matrix)
CO(GT)
PT08.S1(CO)
C6H6(GT)
PT08.S2(NMHC)
NOx(GT)
PT08.S3(NOx)
NO2(GT)
PT08.S4(NO2)
PT08.S5(O3)
-0.75
-0.17
-0.57
-0.50
-0.53
-0.60
-0.48
-0.41
-0.73
IC1
IC2
IC3
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4
−0.6
−0.8

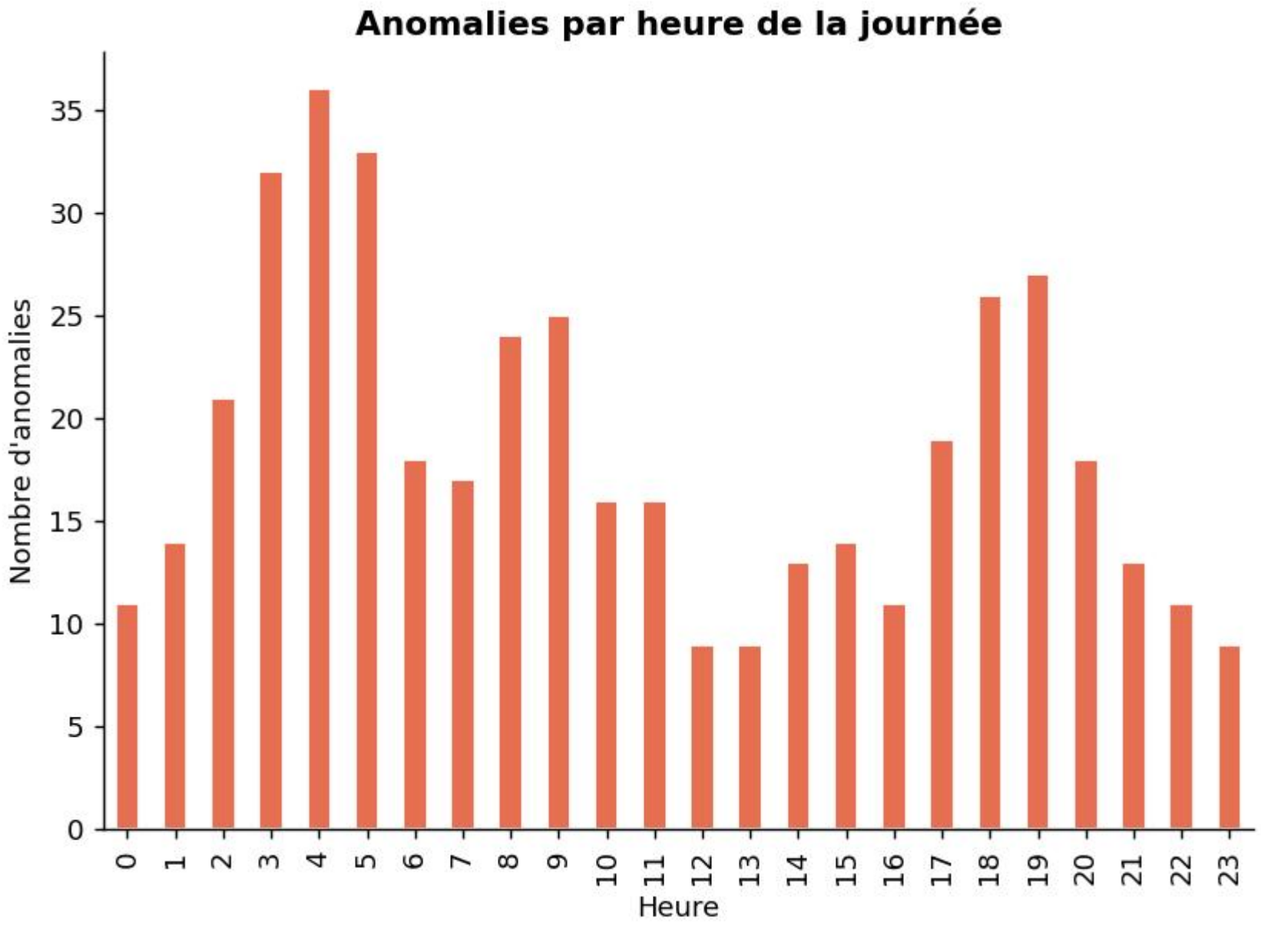
Anomalies par heure de la journée
Nombre d'anomalies
0
5
10
15
20
25
30
35
0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23
Heure

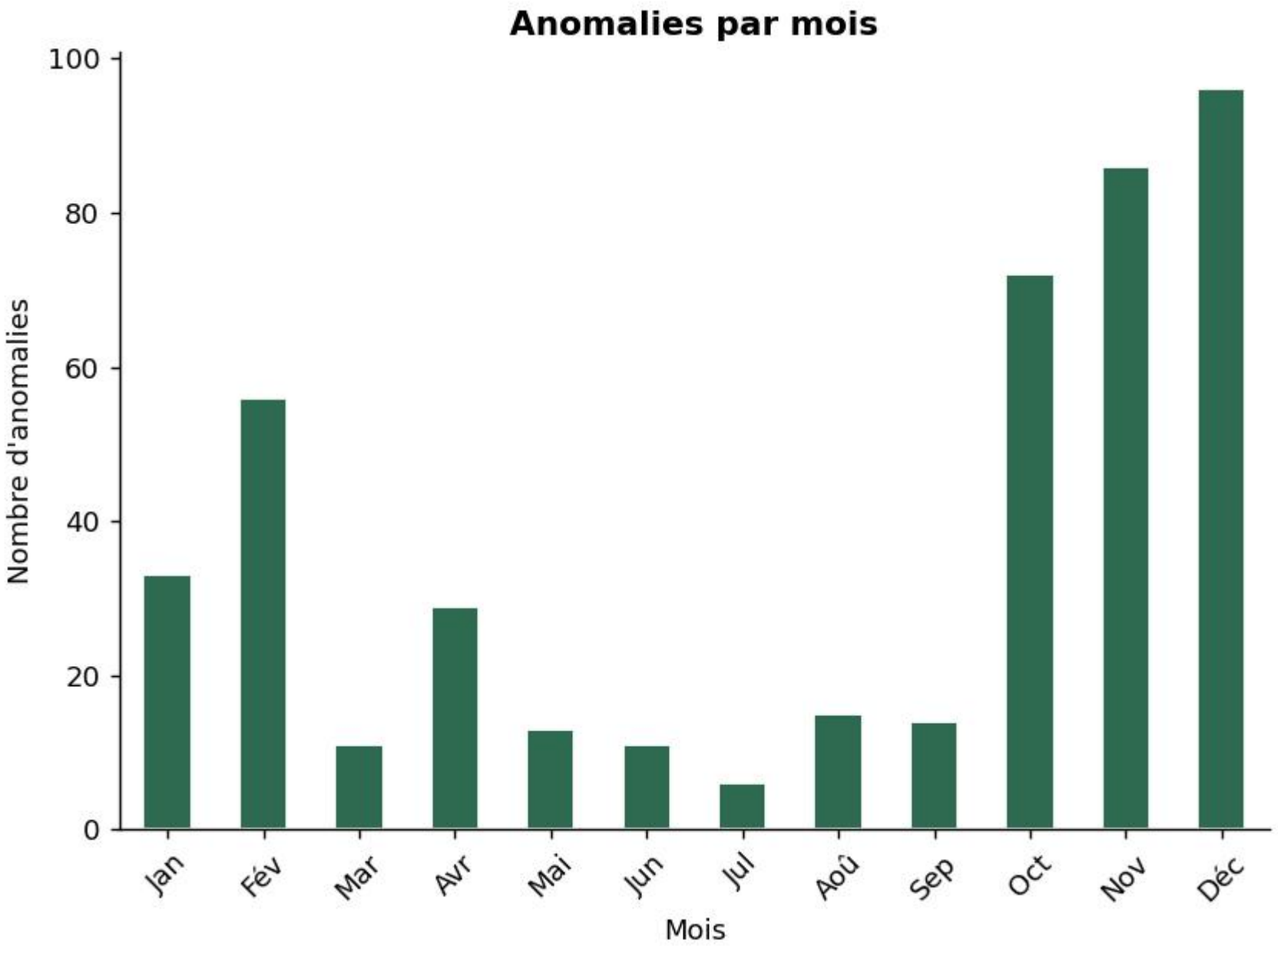
Anomalies par mois
Nombre d'anomalies
0
20
40
60
80
100
Jan Fév Mar Avr Mai Jun Jul Aoû Sep Oct Nov Déc
Mois